

25-2 DSL 정규 세션

Machine Learning 과제



- 본 과제는 학회 정규 세션 「Regression」, 「Classification」, 「Clustering」, 「Dimensionality Reduction」의 내용을 다루며, 개념의 적용과 실제 활용 사례에 대한 이해를 돋기 위해 기획되었습니다. 해당 과제는 평가를 위한 것이 아니므로, 주어진 힌트(💡)를 적극 활용하시고 학회원 간 토론 및 Slack 질의응답을 적극 활용하여 해결해주십시오. 단, 답안 표절이나 LLM의 남용은 금지합니다.
- 서술형 문제는 📜, 코딩 문제는 💻으로 표기가 되어 있습니다. 각 문제에서 요구하는 방법에 맞게 해결하며, 서술형 문제들은 따로 작성하시어 .pdf 파일로, 코딩 문제들은 주어진 .ipynb 파일에 답안을 작성하여 제출해 주십시오.
- 8/20 (수) 23 시 59 분까지 Github에 .pdf 파일과 .ipynb 파일들을 압축하여 하나의 .zip 파일로 끌어 제출해 주십시오. Github에 제출하는 방법을 모른다면 학술부장 혹은 과제 질의응답을 위한 오픈채팅방을 적극적으로 활용해 주십시오.

문제 1 Linear Regression

Regression은 독립변수가 종속변수에 영향을 미치는지 알아보기 위해 실시하는 분석 방법으로, 변수들 간의 관계를 정량적으로 모델링하고 예측하는 데 사용됩니다. 대표적인 유형으로는 Linear Regression(독립변수와 종속변수 간 선형 관계를 가정)과 Logistic Regression(종속변수가 범주형일 때 사용)이 있습니다. 실제 예측 성능을 높이기 위해서는 불필요한 변수를 제거하는 변수 선택(Variable Selection)과 과정화(overfitting)을 고려하여 제곱오차의 음수 형태가 된 방지하기 위한 정규화(Regularization) 기법이 함께 사용됩니다.

따라서 MLE는 제곱오차 최소화를 수행하는 OLS와 동일한 해를 낸다.

로그우도는 concave, 제곱오차는 convex라 최적해가 유일하게 보장된다.

1-1 👍: 관측된 데이터 (x_i, y_i) 가 다음과 같은 선형 회귀 모델을 따른다고 가정합니다:

$$y_i = x_i^T w + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2)$$

1) OLS를 사용하여 $L(w) = \sum_{i=1}^n (y_i - x_i^T w)^2$ 를 최소화하는 \hat{w} 를 구하세요.

$$L(w) = \sum_{i=1}^n (y_i - x_i^T w)^2 = \|y - Xw\|^2$$

$$\nabla_w L(w) = 2X^T X w - 2X^T y = 0 \Rightarrow X^T X \hat{w} = X^T y$$

$$\therefore \hat{w}_{OLS} = (X^T X)^{-1} X^T y$$

2) 위 모델에서 y_i 의 조건부 확률분포 $p(y_i | x_i; w)$ 를 바탕으로 w 의 MLE 추정량을 유도하세요.

$$\varepsilon_i \sim N(0, \sigma^2) \text{ 가정. } p(y_i | x_i; w) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - x_i^T w)^2}{2\sigma^2}\right)$$

$$l(w, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|y - Xw\|^2 \quad \therefore \hat{w}_{MLE} = (X^T X)^{-1} X^T y, \quad \hat{\sigma}^2 = \frac{1}{n} \|y - X\hat{w}\|^2$$

3) 두 접근법의 결과를 비교하고, 그러한 결과가 나타난 이유를 설명하세요.

💡 OLS 와 MLE 모두 convex function을 최소화하는 문제로 변환됩니다.

정규오차를 가정하면 로그오차함수는 상수함수를 제외하면 제곱오차의 등수함수가 된다.

따라서 MLE는 제곱오차 함수를 수행하는 OLS와 동일한 해를 낸다.

25-2 Machine Learning 과제 \Rightarrow 로그우도는 concave, 제곱오차는 convex이다

유일한 최적해가 보장됨.

1-2 📈 : Feature Selection.ipynb 를 참조해주세요 .

💡 Regression 의 변수 선택 기법에는 대표적으로 Forward Selection 과 Backward Selection 이 있습니다. Forward Selection 은 빈 모델(변수 없음)에서 시작하여 설명력이 가장 높은 변수부터 하나씩 추가해나가는 방식입니다. 각 단계에서 가장 유의미한 변수를 추가하고, 모델의 성능이 더 이상 향상되지 않으면 선택을 중단합니다. Backward Selection 은 모든 변수를 포함한 모델에서 시작하여, 가장 덜 유익한 변수부터 하나씩 제거하는 방식입니다. 각 변수의 기여도를 평가하여 성능 향상에 방해가 되는 변수를 제거하며, 지정된 기준을 충족하지 못하면 더 이상 제거하지 않습니다.

💡 변수 선택의 기준으로는 AIC, BIC, R², Adjusted R² 등이 사용됩니다. AIC 와 BIC 는 모두 회귀 모델의 성능과 복잡도를 동시에 고려하며, 값이 작을수록 더 좋은 모델을 의미합니다. Adjusted R²은 변수가 많아질수록 자동으로 R²이 올라가는 현상을 방지하고, 불필요한 변수 추가시 감소하도록 보정된 지표입니다.

💡 VIF 는 다중공선성 문제를 진단하기 위한 지표입니다. VIF > 10 이면 해당 변수는 다른 변수와 강한 상관관계가 있으며 제거를 고려해야 합니다.

💡 QQ-Plot 은 잔차가 정규분포를 따르는지 시각적으로 진단하며, Residual Plot 은 잔차의 등분산성을 진단할 수 있습니다.



1-3 🔔 : 회귀분석에서의 정규화(Regularization)는 다음과 같이 목적 함수 + 제약 조건의 구조로 이해할 수 있습니다.

💡 Ridge 회귀는 다음과 같은 constrained optimization 문제로 표현할 수 있습니다.

$$\min_{\beta} \|y - X\beta\|^2 \quad \text{subject to} \quad \sum_{j=1}^p \beta_j^2 \leq t$$

이는 라그랑주 승수법을 사용하여 penalty term 으로 바꾸면 다음과 같은 형태의 목적함수로 바뀝니다.

$$L(\beta, \lambda) = \|y - X\beta\|^2 + \lambda \sum_{j=1}^p \beta_j^2$$

비슷하게 Lasso 회귀는 다음과 같은 문제로 표현됩니다.

$$\min_{\beta} \|y - X\beta\|^2 \quad \text{subject to} \quad \sum_{j=1}^p |\beta_j| \leq t$$

역시 penalty 항을 이용해 다음과 같은 목적함수로 바꿀 수 있습니다.

$$L(\beta, \lambda) = \|y - X\beta\|^2 + \lambda \sum_{j=1}^p |\beta_j|$$

1) Lasso 회귀는 Ridge 회귀와 어떤 점에서 penalty 항이 다른지, 그리고 이로 인해 기대할 수 있는 효과의 차이를 간략히 설명하세요.

Ridge는 L2 패널티로 계수를 연속적으로 축소시켜 안정성을 높이지만, 거의 0이 되지는 않는다.

Lasso는 L1 패널티로 목적함수가 convex이면서 원점에 뾰족한 형태라 일부 계수를 정확히 0으로 만든다.

따라서 Ridge는 모든 변수를 조금씩 활용하고, Lasso는 변수 선택 기능을 가진다.

2) Lasso 회귀는 Ridge 와 달리 해석해(closed-form solution)가 존재하지 않습니다. 그 이유에 대해 설명하세요.

L1 패널티는 원점에서 미분이 안 되기 때문에 수학적으로 딱 떨어지는 공식 해를 얻기 어렵다.

아주 특수한 경우인 직교 설계에서는 각 계수별 공식이 나오지만 현실의 데이터는 대부분 그렇지 않다.

그래서 일반적으로는 좌표강하법 같은 반복 알고리즘으로 해를 구한다.

문제 2 (Soft-Margin) SVM

SVM은 데이터를 명확하게 구분할 수 있는 마진을 최대화하는 초평면을 찾는 지도 학습 알고리즘입니다.
Slack Variable을 도입해 오차를 허용하는 SVM의 목적 함수는 아래와 같습니다.

$$\begin{aligned} & \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i \\ & \text{subject to } y^{(i)} (\mathbf{w}^\top \mathbf{x}^{(i)} + b) \geq 1 - \xi_i, \quad \forall i = 1, \dots, N, \\ & \quad \xi_i \geq 0, \quad \forall i = 1, \dots, N. \end{aligned}$$

Slack Variable(ξ_i): 오차를 허용할 때 사용하는 변수

C: margin과 training error 간 trade-off를 조절하는 하이퍼 파라미터

2-1 🔥: 아래의 목적 함수가 위의 목적 함수와 같음을 보이세요.

$$\min_{\mathbf{w}, b} L(\mathbf{w}, b) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \max(0, 1 - y^{(i)} (\mathbf{w}^\top \mathbf{x}^{(i)} + b))$$

2-2 🔥: 우리는 SGD(Stochastic Gradient Descent) 방식으로 SVM을 train시키고자 합니다.
먼저 SGD에 대해서 Loss Function은 다음과 같이 정의됩니다.

$$L(\mathbf{w}, b) = \frac{1}{2} \|\mathbf{w}\|^2 + C \cdot \max(0, 1 - y_i (\mathbf{w}^\top \mathbf{x}_i - b))$$

Gradient Descent 방법이기에, 손실 함수의 가중치에 대한 기울기($\frac{\partial L}{\partial w}$)와 손실 함수의 편향에 대한 기울기($\frac{\partial L}{\partial b}$)를 구해야 합니다. 이는 다음과 같습니다.

$$\frac{\partial L}{\partial \mathbf{w}} = \begin{cases} \mathbf{w} & \text{if } y_i (\mathbf{w}^\top \mathbf{x}_i - b) \geq 1 \\ \mathbf{w} - C \cdot y_i \mathbf{x}_i & \text{if } y_i (\mathbf{w}^\top \mathbf{x}_i - b) < 1 \end{cases}$$

$$\frac{\partial L}{\partial b} = \begin{cases} 0 & \text{if } y_i (\mathbf{w}^\top \mathbf{x}_i - b) \geq 1 \\ C \cdot y_i & \text{if } y_i (\mathbf{w}^\top \mathbf{x}_i - b) < 1 \end{cases}$$

위의 기울기 식들이 성립함을 증명하세요.

💡 Loss Function과 if 조건문의 관련성을 보세요!

2-1

$$\xi_i \geq 1 - y^{(i)} (w^\top x^{(i)} + b), \quad \xi_i \geq 0$$

$$\xi_i^* = \max(0, 1 - y^{(i)} (w^\top x^{(i)} + b))$$

$$\min_{w, b, \xi \geq 0} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \quad \text{s.t. } \xi_i \geq 0, \quad \xi_i \geq 1 - M_i.$$

$$= \min_{w, b} \frac{1}{2} \|w\|^2 \sum_{i=1}^N \min_{\xi_i \geq 0, \xi_i \geq 1 - M_i} C \xi_i$$

$$= \min_{w, b} \frac{1}{2} \|w\|^2 \left(\sum_{i=1}^N \max \{0, 1 - M_i\} \right)$$

$$= \min_{w, b} \frac{1}{2} \|w\|^2 \left(\sum_{i=1}^N \max(0, 1 - y_i (w^\top x_i + b)) \right)$$

$$\therefore \min_{w, b, \xi \geq 0} \frac{1}{2} \|w\|^2 + C \sum_i \xi_i \text{ s.t. } y_i (w^\top x_i + b) \geq 1 - \xi_i \equiv \min_{w, b} \frac{1}{2} \|w\|^2 + C \sum_i \max(0, 1 - y_i (w^\top x_i + b))$$

2-2

$$m_i = y_i (w^\top x_i + b) \Rightarrow h(M_i) = \max(0, 1 - M_i)$$

$$M_i > 1 \rightarrow h(M_i) = 0, \quad \frac{\partial h}{\partial M_i} = 0$$

$$M_i < 1 \rightarrow h(M_i) = 1 - M_i \Rightarrow \frac{\partial h}{\partial M_i} = -1$$

$M_i = 1 \rightarrow [-1, 0]$ 범위의 subgradient of.

$$\frac{1}{2} \|w\|^2 \text{ for } \frac{\partial}{\partial w} = \frac{1}{2} \|w\|^2 = w$$

$$m_i = y_i (w^\top x_i + b) \text{ for } \frac{\partial m_i}{\partial w} = y_i x_i. \quad \frac{\partial m_i}{\partial b} = y_i$$

$$\frac{\partial L}{\partial w} = w + C \cdot \frac{\partial b}{\partial m_i} \cdot \frac{\partial m_i}{\partial w} = w - C \cdot \hat{s}_i \cdot y_i$$

$$\frac{\partial L}{\partial b} = C \cdot \frac{\partial h}{\partial M_i} \cdot \frac{\partial M_i}{\partial b} = C \cdot \hat{s}_i \cdot (-y_i)$$

$(\hat{s}_i \in \{0, -1\})$ 이를 문제에 제시한 가로기식 막을

2-3 📈 : SVM.ipynb 를 참조하세요.

💡 2-2 결과와 아래 알고리즘을 참고하면 도움이 될겁니다!

Algorithm 1 SVM Training with Stochastic Gradient Descent

```
Initialize weights  $\mathbf{w} \leftarrow 0$  and bias  $b \leftarrow 0$ 
for iteration = 1 to  $n\_iters$  do
    for each sample  $(\mathbf{x}_i, y_i)$  in dataset do
        Compute condition
        if condition is True then
            Update  $\mathbf{w} \leftarrow \mathbf{w} - \text{learning\_rate} \cdot \frac{\partial L}{\partial \mathbf{w}}$ 
        else
            Update  $\mathbf{w} \leftarrow \mathbf{w} - \text{learning\_rate} \cdot \frac{\partial L}{\partial \mathbf{w}}$ 
            Update  $b \leftarrow b - \text{learning\_rate} \cdot \frac{\partial L}{\partial b}$ 
        end if
    end for
end for
return weights  $\mathbf{w}$  and bias  $b$ 
```

문제 3 EM algorithm

이번 문제에서는 숨겨진 변수(latent variable)가 포함된 확률 모델에서 최대우도추정(MLE)을 수행하는 대표적 기법인 Expectation-Maximization(EM) 알고리즘을 다루고자 합니다. EM 알고리즘은 관측되지 않은 변수로 인해 직접 최적화가 어려운 상황에서, 반복적인 기대-최대화 단계를 통해 수렴 가능한 근사 최적해를 찾는 과정을 제시합니다. 본 문제를 통해 EM 알고리즘이 어떻게 유도되며, 구체적으로 Gaussian Mixture Model(GMM)에 어떻게 적용되는지를 수학적으로 해석하고 분석해보는 것이 목적입니다.

3-1 🔥 : 잠재 변수 Z 가 있는 경우, Likelihood 함수는 $L(\theta; X, Z) = p(X, Z|\theta)$ 로 정의됩니다. θ 에 대한 MLE, 관측한 데이터 X 가 가장 잘 설명되도록 하는 파라미터 θ 를 찾는 방법은 X 에 대한 Marginal Likelihood $p(X|\theta)$ 를 최대화하는 것입니다. 이것이 EM 알고리즘의 다음 두 단계를 반복하며 구해질 수 있음을 보이세요.

$$E-step : Q(\theta|\theta^{(t)}) = E_{Z \sim p(Z|X,\theta^{(t)})} [\log p(X, Z|\theta)]$$
$$M-step : \theta^{(t+1)} = \underset{\theta}{\operatorname{argmax}} Q(\theta|\theta^{(t)})$$

($\theta^{(t)}$ 는 t 번째 iteration에서의 parameter 값)

💡 $\log p(X|\theta) = \log \frac{p(X,Z|\theta)}{p(Z|X,\theta)}$

💡 $: Q(\theta|\theta^{(t)}) = E_{Z \sim p(Z|X,\theta^{(t)})} [\log p(X, Z|\theta)] = \sum_Z p(Z|X, \theta^{(t)}) \log p(X, Z|\theta)$

3-2 🎉 : GMM 의 파라미터를 EM 알고리즘을 통해 추정할 때, $Q(\theta | \theta^{(t)})$ 는 다음과 같이 표현할 수 있습니다.

$$\begin{aligned}
Q(\theta | \theta^{(t)}) &= E_{Z|X, \theta^{(t)}}[\log f_\theta(Z, X)] \\
&= \sum_{i=1}^n E_{Z_i|X_i, \theta^{(t)}}[\log f_\theta(Z_i, X_i)] \\
&= \sum_{i=1}^n \sum_{k=1}^K \gamma_{k,i,\theta^{(t)}} \log P(Z_i = k, X_i | \theta) \\
&= \sum_{i=1}^n \sum_{k=1}^K \gamma_{k,i,\theta^{(t)}} \log [w_k \mathcal{N}(X_i | \mu_k, \Sigma_k)] \\
\gamma_{k,i,\theta^{(t)}} &= P(Z_i = k | X_i, \theta^{(t)}) \\
&= \frac{P(Z_i = k | \theta^{(t)}) \cdot P(X_i | Z_i = k, \theta^{(t)})}{\sum_{j=1}^K P(Z_i = j | \theta^{(t)}) \cdot P(X_i | Z_i = j, \theta^{(t)})} \\
&= \frac{w_k^{(t)} \mathcal{N}(X_i | \mu_k^{(t)}, \Sigma_k^{(t)})}{\sum_{j=1}^K w_j^{(t)} \mathcal{N}(X_i | \mu_j^{(t)}, \Sigma_j^{(t)})}
\end{aligned}$$

(n 은 관측 데이터의 개수, K 는 cluster 의 개수, $\gamma_{k,i,\theta^{(t)}}$ 는 책임값(Responsibility)로 X_i 가 k 번째 gaussian 분포에 속할 확률, $w_k^{(t)}$ 는 데이터 Z_i 가 cluster k 에 속할 확률, $\mu_k^{(t)}$ 와 $\Sigma_k^{(t)}$ 는 각각 k 번째 gaussian 분포의 평균과 공분산)

이때 EM 알고리즘으로 다음 파라미터 $w_k^{(t+1)}$ 이 아래와 같이 추정됨을 보이세요

$$w_k^{(t)} = \frac{1}{n} \sum_{i=1}^n \gamma_{k,i,\theta^{(t)}}$$

💡 w_k 는 확률값이므로 다음 제약 조건을 만족해야합니다. (Lagrange Multiplier 를 활용해보세요.)

$$\sum_{k=1}^K w_k = 1 \text{ and } w_k \geq 0$$

💡 동일한 논리로 모든 k 에 대한 책임값 $\gamma_{k,i,\theta^{(t)}}$ 들의 합 또한 1 입니다.



3-3 🎉 (Optional) : 또한 $\mu_k^{(t+1)}$ 과 $\Sigma_k^{(t+1)}$ 이 아래와 같이 추정됨을 보이세요.

$$\begin{aligned}
\mu_k^{(t+1)} &= \frac{\sum_{i=1}^n \gamma_{k,i,\theta^{(t)}} X_i}{\sum_{i=1}^n \gamma_{k,i,\theta^{(t)}}} \\
\Sigma_k^{(t+1)} &= \frac{1}{\sum_{i=1}^n \gamma_{k,i,\theta^{(t)}}} \sum_{i=1}^n \gamma_{k,i,\theta^{(t)}} (X_i - \mu_k^{(t+1)}) (X_i - \mu_k^{(t+1)})^T
\end{aligned}$$

$$3-1) \quad \log p(x|\theta) = \log \cdot \sum_z p(x, z|\theta)$$

①. $q(z)$ et Jensen 부등식 적용.

$$\log p(x|\theta) = \log \sum_z q(z) \frac{p(x, z|\theta)}{q(z)}$$

$$\log p(x|\theta) \geq \sum_z q(z) \log \frac{p(x, z|\theta)}{q(z)}$$

② ELBO

$$L(q, \theta) = E_q (\log p(x, z|\theta)) + H(q)$$

기대값과 단위부호

에ント로피

E-step 특징 $\theta^{(t)}$ 가 주어지면. $\log p(x|\theta)$ 와 같은 것들이 같아지면

$$q(z) = p(z|x, \theta^{(t)})$$

$$\Rightarrow Q(\theta|\theta^{(t)}) = E_{z|x, \theta^{(t)}} (\log p(x, z|\theta))$$

M-step $Q(\theta|\theta^{(t)})$ 를 θ 의 최적값으로 $\Rightarrow \theta^{t+1} = \arg \max_{\theta} Q(\theta|\theta^{(t)})$

\Rightarrow E-M step 반복하면 $p(x|\theta)$ 값이 더 커지게 됨.
(각각의 확률) ↳ responsibility

$$3-2) \quad \text{M-step에서 } Q(\theta|\theta^{(t)}) = \sum_{i=1}^n \sum_{k=1}^K r_{ik}^{(t)} \log w_k N(x_i | \mu_k, \Sigma_k)$$

$$Q(w) = \sum_{i=1}^n \sum_{k=1}^K r_{ik}^{(t)} \log w_k \text{ 만 } \text{ 대조 } \text{ 봄}$$

$$L(w, \lambda) = \sum_{i=1}^n \sum_{k=1}^K r_{ik}^{(t)} \log w_k + \lambda \left(- \sum_{k=1}^K w_k \right)$$

$$\text{2번 미분} \quad \frac{\partial L}{\partial w_k} = \frac{\sum_{i=1}^n r_{ik}^{(t)}}{w_k} - \lambda \Rightarrow \therefore w_k = \frac{1}{\lambda} \sum_{i=1}^n r_{ik}^{(t)}$$

$$\sum_{k=1}^K w_k = 1 \Rightarrow \frac{1}{\lambda} \sum_{i=1}^n \sum_{k=1}^K r_{ik}^{(t)} = \left(\sum_{k=1}^K r_{ik}^{(t)} \right) \rightarrow K = n$$

$$\therefore w_k^{(t+1)} = \frac{1}{n} \sum_{i=1}^n r_{ik}^{(t)}$$

3-4 GMM.ipynb 는 EM 알고리즘을 활용한 GMM 기반 클러스터링 예시들을 확인해보는 코드를 다루고 있습니다. 코드 내에서 EM 알고리즘으로 추정한 parameter 들이 위 문제에서 유도한 수식과 일치하는지 확인해보세요. 실험 결과와 이론을 대조해보며 알고리즘과 그 활용에 충분한 고민을 해보기 바랍니다.

문제 4 PCA

PCA 는 고차원 데이터의 구조를 요약하는 동시에, 주요 분산 성분만을 보존하고 잡음(노이즈) 성분은 제거하는 효과가 있어, 특징 추출, 전처리, 시각화, 노이즈 제거 등의 다양한 작업에 널리 활용됩니다. 본 문제에서는 이미지 데이터를 입력으로 받아 PCA 를 직접 구현하고, 주성분 수에 따른 압축·복원 결과를 시각적으로 비교합니다. 본 과제의 구현 및 실습은 PCA.ipynb 파일에서 확인할 수 있습니다.

4-1 : PCA 와 PCA 를 이용한 이미지 압축·복원 코드를 완성하고, 결과를 확인하세요.



4-2 : PCA 의 주성분 개수를 조절하며 노이즈 제거 실험을 해보고, 실험 결과를 분석하여 서술하세요.

PCA의 주성분 개수↑ → 노이즈 제거 효과↓ 원본데이터를 훨씬 더 잘 복원.
↓ → 노이즈 제거 효과↑ 이전의 쌍상간수요.

4-3 (Optional): PCA.ipynb 를 수행하면서 느낀 PCA 의 단점에 대해 언급해 보세요. 이 단점을 보완할 수 있는 방법이 있을까요? 생각나는대로 자유롭게 적어보세요.

💡 PCA 의 시간 복잡도는 어떻게 될까요?

💡 https://en.wikipedia.org/wiki/Power_iteration

PCA는 선형성을 전제로 하기 때문에, 데이터가 비선형 구조를 가질 경우 정보 손실이 크고 주성분의 해석이 어렵다. 큰 단점인지는 모르겠는데 데이터가 스케일에 민감하여 표준화가 필요하다. 보완 방법으로는 kernel pca, auto encoder 등이 있다고 합니다.

Reference

- 24-2 Regression + SVM + 비지도학습 (11 기 김현진, 김정우)
- 25-1 Machine Learning (12 기 김은희, 이정우)
- 25-1 Unsupervised Learning #2 (12 기 복지민)
- Statistical Machine Learning, Prof. Lee, Spring 2024, Yonsei Univ.
- Deep Learning, Prof. Park, Spring 2025, Yonsei Univ
- Regression Analysis, Prof. Jeon, Fall 2023, Yonsei Univ.
- Bishop, C. M. (2006). Pattern recognition and machine learning. Springer.

Data Science Lab

담당자: 13 기 강승우, 한연주
ksw030721@yonsei.ac.kr
amiee1510@gmail.com