

행벡터  $1 \times n$  행렬  $[ \quad ]$   
 열벡터  $n \times 1$  열렬  $\begin{bmatrix} - \\ - \\ - \end{bmatrix}$

미분한 값은 열벡터 형태를 써야함!

1-1. (1)

$$L(w) = (y - Xw)^T (y - Xw)$$

$$\therefore (Xw)^T = w^T X^T$$

$$= y^T y - \underbrace{y^T X w}_{\text{①}} - \underbrace{w^T X^T y}_{\text{②}} + w^T X^T X w$$

$$\frac{dL(w)}{dw} = 0 - \underbrace{2y^T X}_{\text{①: } 1 \times n \cdot n \times d = 1 \times 1} - \underbrace{2X^T X w}_{\text{②: } 1 \times d \cdot d \times n \cdot n \times 1 = 1 \times 1} \Rightarrow 2y^T X w$$

$$= 0 - 2X^T y + 2X^T X w = 0 \text{ 인 } w \text{ 를 찾는 문제}$$

$$X^T X w = X^T y$$

$$\hat{w} = (X^T X)^{-1} X^T y$$

1-1 (2)

$$L(w) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(y_i - x_i^T w)^2}{2\sigma^2}\right)$$

$$\log L(w) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - x_i^T w)^2 + \log \frac{1}{\sqrt{2\pi}} n$$

MLE (최대우도추정) 추정량  $\Rightarrow$  로그가 최대가 되는  $w$  값 찾는 문제

$\Rightarrow$  ————— 절댓값이 최소가 되는  $w$  값을 찾는 문제

$$\sum_{i=1}^n (y_i - x_i^T w)^2 = (y - Xw)^T (y - Xw) \text{ 이 최소가 되는 } w \text{ 값}$$

$$\therefore \hat{w} = (X^T X)^{-1} X^T y$$

1-1 (3)

OLS와 MLE 모두 Convex function을

최소화하는 문제로 바뀌고 그 결과값은

$(X^T X)^{-1} X^T y$  로 서로 같게 된다.

1-3 e

1) Ridge  $L_2$  패널티      Lasso  $L_1$  패널티  
 $\lambda \sum_{j=1}^p \beta_j^2$  형태      vs       $\lambda \sum_{j=1}^p |\beta_j|$  형태

$L_2$  제약은 개회항으로 원형대이므로, 보라기 없이 계수들이 연속적으로 줄어든다

$L_1$  제약은 하등보 형태이므로, 해가 보라기 있게 되면 계수가 정확히 0이 될 수 있다

즉 Ridge는 계수를 0으로 만들지는 못하지만 다중공선성을 완화할 수 있고

Lasso는 <sup>불필요한</sup> 변수를 0으로 만들 수 있어 변수선택에 용이하다

2) Ridge <sup>L2</sup> 패널티는  $\beta_j^2$  형태로 미분하여 0이 되는 해가 존재한다. 따라서 해석해가 존재할 수 있다.

반면에 Lasso  $L_1$  형태는  $|\beta_j|$  (절댓값) 형태로 ~~미분할 수 없는 점이 존재하기 때문에~~ 해석해가 없다  
 미분하여 0이 되는 곳이 없기에



2-1

$\varepsilon_i > 0$  이고,  $\varepsilon_i > 1 - y^{(i)}(w^T x^{(i)} + b)$  이므로

$$\min_{w, b} \left( \frac{1}{2} \min \left( C \sum_{i=1}^n \varepsilon_i \right) \right) = \min \left( C \sum_{i=1}^n \max(0, 1 - y^{(i)}(w^T x^{(i)} + b)) \right) \text{ 이다}$$

=  $\min_{w, b} \Rightarrow \varepsilon_i$ 를 가장 작은 가장 작은 값은 0 이고  $1 - y^{(i)}(w^T x^{(i)} + b)$ 가 0보다 클 때

2-2

$$L(w, b) = \frac{1}{2} \|w\|^2 + C \cdot \max(0, 1 - y_i(w^T x_i + b)) \quad \text{Z 라면 2라 하면}$$

마진을 크게 만드는게  $1 - y_i(w^T x_i + b) > 0$  이면  $\varepsilon_i$ 를 부가한다

$$1) \frac{1}{2} \|w\|^2 \text{ 미분} = \frac{d}{dw} \frac{1}{2} w^T w = w$$

$$2) \underbrace{1 - y_i(w^T x_i + b)}_{\text{마진}} \text{ 미분} \Rightarrow \frac{d}{dw} (1 - y_i(w^T x_i + b)) = -y_i x_i$$

$$\therefore \frac{dL}{dw} = \begin{cases} w & (z=0 \text{ 이 } 1 - y_i(w^T x_i + b) \leq 0 = y_i(w^T x_i + b) > 1) \\ w + C \times (-y_i x_i) & (z=1 - y_i(w^T x_i + b) > 0 \Rightarrow y_i(w^T x_i + b) < 1) \end{cases}$$

$$\frac{dL}{db} = \begin{cases} 0 & \text{if } 1 - y_i(w^T x_i + b) \leq 1 \\ C \frac{d}{db} (y_i b) = C \times y_i & \text{if } 1 - y_i(w^T x_i + b) > 0 \end{cases}$$

3-1

$$\log P(x|b) = \log \sum_z q(z) \frac{p(x, z|b)}{q(z)} \stackrel{\text{ Jensen }}{\geq} \sum_z q(z) \log \frac{p(x, z|b)}{q(z)}$$

$$\leftarrow \sum_z q(z) \log \frac{p(x, z|b)}{q(z)} = \sum_z q(z) \log p(x, z|b) - \sum_z q(z) \log q(z)$$

$\mathcal{F}(q, b)$

$$\sum_z q(z) \log p(x, z|b) = \sum_z q(z) [\log p(z|x, b) + \log p(x|b)]$$

$$= \sum_z q(z) \log p(z|x, b) + \sum_z q(z) \log p(x|b)$$

$$= \sum_z q(z) \log p(z|x, b) + \log p(x|b)$$

$$\mathcal{F}(q, b) = \sum_z q(z) \log p(z|x, b) + \log p(x|b) - \sum_z q(z) \log q(z)$$

$$= \log p(x|b) + \sum_z q(z) \log p(z|x, b) - \sum_z q(z) \log q(z)$$

$$= \log p(x|b) - KL(q(z) || p(z|x, b))$$

$$\log p(x|b) = \mathcal{F}(q, b) + \frac{KL(q(z) || p(z|x, b))}{\geq 0}$$



$$KL(q(z) || p(z | y, \theta)) = 0 \Leftrightarrow q(z) = p(z | y, \theta)$$

$$\therefore \text{E-step에서 } q(z) = p(z | y, \theta^{(t)}) \text{ 일 때}$$

$$\log p(x | \theta) = F(q, \theta) \text{ 이 된다. (최대가 된다)}$$

$$\text{이때의 } q(z) = p(z | y, \theta) \text{ 를 E-step에서 갱신한다}$$