



1-1 📌: 주사위를 던졌을 때 나오는 눈의 사건을 X 라 하고, 각 눈이 나올 확률을 p_i ($0 \leq p_i \leq 1$, $\sum_{i=1}^6 p_i = 1$) 이라 할 때, 아래의 조건에서 주사위의 엔트로피 $H(X)$ 를 각각 구하세요. $H(X)$ 는 언제 최대가 되는지 간단한 이유 (내지는 직관)와 함께 서술하세요.

💡 엔트로피의 정의: $H(X) = \sum_{x \in X} p(x) \log_2 \{1/p(x)\} = \sum_{x \in X} -p(x) \log_2 \{p(x)\}$

1) 공정한 주사위 (모든 $p_i = 1/6$)

2) 모든 눈이 6 인 주사위

$$2x \quad x \quad \rightarrow \quad 9x = 1 \quad . \quad x = \frac{1}{9}$$

3) 짝수 눈이 나올 확률이 홀수 눈이 나올 확률의 2 배인 주사위(짝수 각각 및 홀수 각각의 확률은 동일)

4) 1 이 나올 확률이 0.5, 나머지 눈이 나올 확률이 각각 0.1 인 주사위

$$1) H(X) = 6 \times \frac{1}{6} \log_2 6 = \log_2 6 \approx 2.6$$

$$2) H(X) = 1 \log_2 1 = 0$$

$$\begin{aligned} 3) H(X) &= - 3 \times \frac{1}{9} \log_2 \frac{1}{9} - 3 \times \frac{2}{9} \log_2 \frac{2}{9} \\ &= - \frac{1}{3} \log_2 \frac{1}{9} - \frac{2}{3} \log_2 \frac{2}{9} \\ &= - \frac{2}{3} \log_2 \frac{1}{3} - \frac{2}{3} \log_2 \frac{2}{9} \\ &= - \frac{2}{3} \log_2 \frac{1}{3} \cdot \frac{2}{9} \\ &= - \frac{2}{3} \log_2 \frac{2}{27} \approx 2.5 \end{aligned}$$

$$\begin{aligned} 4) H(X) &= - 0.5 \log_2 0.5 - 5 \times 0.1 \log_2 0.1 \\ &= \frac{1}{2} \log_2 2 - \frac{1}{2} \log_2 10 \\ &= \frac{1}{2} \log_2 2 \times 10 \\ &= \frac{1}{2} \log_2 20 \approx 2.2 \end{aligned}$$

엔트로피는 불확실성의 척도.

가능한 결과들이 확률이 고르게 분포할수록 불확실성이 크고, 엔트로피가 크다.

1-2 🍌: 임의의 이산확률변수 X 에 대하여 X 가 가질 수 있는 값의 집합을 \mathcal{X} 라 합니다. 예를 들어, 동전을 1회 던졌을 때의 $\mathcal{X} = \{Head, Tail\}$ 로 $|\mathcal{X}| = 2$ 입니다. 이때 엔트로피 $H(X)$ 가 가질 수 있는 값의 범위가 $0 \leq H(X) \leq \log_2 |\mathcal{X}|$ 임을 증명하세요.

💡 좌측 부등식의 경우, 확률 값의 성질을 활용해 증명 가능합니다.

💡 우측 부등식의 경우, 아래의 Jensen's Inequality를 활용해 증명 가능합니다.

- Jensen's Inequality: $\mathbb{E}[f(X)] \geq f(\mathbb{E}[X])$ for a convex f , and $\mathbb{E}[f(X)] \leq f(\mathbb{E}[X])$ for a concave f
(Bonus Question: Jensen's Inequality는 어떻게 증명할까요? Hint: 수학적 귀납법으로 $n=2$ 부터...!)

$$1) 0 \leq H(X)$$

$$0 \leq p(x) \leq 1 \quad \log_2 p(x) \leq 0$$

$$-p(x) \log_2 p(x) \geq 0$$

$$H(X) \geq 0$$

$$2) H(X) \leq \log_2 |\mathcal{X}|$$

$$H(X) = - \sum p(x) \log_2 p(x)$$

$$= \sum p(x) \log_2 \frac{1}{p(x)}$$

$$= \mathbb{E} \left[\log_2 \frac{1}{p(X)} \right] \leq \log_2 \left(\mathbb{E} \left[\frac{1}{p(X)} \right] \right)$$

$$= \log_2 n$$

$$= \log_2 |\mathcal{X}|$$

$$\therefore 0 \leq H(X) \leq \log_2 |\mathcal{X}|$$

1-3 📌: 어떤 지역 주민들의 흡연 여부 (X)와 폐암 발병 여부 (Y)에 대한 설문 조사를 실시하여 다음과 같은 결합 확률 분포를 얻었다고 가정합니다. 여기서 $X = 1$ 은 폐암 발병, $X = 0$ 은 폐암 미발병을 의미하며, $Y = 1$ 은 흡연, $Y = 0$ 은 비흡연을 의미합니다. 아래 질문에 답해주세요.

$P(X, Y)$	$Y = 0$ (비흡연)	$Y = 1$ (흡연)
$X = 0$ (폐암 미발병)	0.45	0.15
$X = 1$ (폐암 발병)	0.1	0.3

- 1) 폐암 발병 여부 X와 흡연 여부 Y의 엔트로피 $H(X)$, $H(Y)$ 를 계산하시오.
- 2) X와 Y의 결합 엔트로피 $H(X, Y)$ 를 계산하시오.
- 3) 흡연 여부 Y에 대한 정보가 주어졌을 때, 폐암 발병 여부 X의 조건부 엔트로피 $H(X|Y)$ 를 계산하시오.
- 4) 폐암 발병 여부 X와 흡연 여부 Y의 Mutual Information $I(X; Y)$ 를 계산하시오.
- 5) 4)의 결과로 나온 $I(X; Y)$ 의 의미를 통계적 관점에서 간략하게 해석하고, $I(X; Y)$ 값이 0일 경우와, $H(X)$ 와 같을 경우 각각 어떤 의미를 갖는지 설명하시오.

💡 엔트로피 계산 시 \log 의 밑은 2로 계산하면 됩니다.
 💡 단위는 비트(bits)를 이용하며, log 계산 값은 근사치로만 이용하시면 됩니다.

$$5) I(X; Y) = H(X) - H(X|Y)$$

$I(X; Y) > 0 \rightarrow Y$ 는 X 에 대한 정보를 제공

$I(X; Y) = 0 \rightarrow X$ 와 Y 는 독립

$I(X; Y) = H(X) \rightarrow Y$ 를 알면 X 는 예측 가능

$$1) H(X) = -\sum P(x) \log_2 P(x)$$

$$= -0.6 \log_2 0.6 - 0.4 \log_2 0.4$$

$$\approx 0.97$$

$$H(Y) = -\sum P(y) \log_2 P(y)$$

$$= -0.55 \log_2 0.55 - 0.45 \log_2 0.45$$

$$\approx 0.99$$

$$2) H(X, Y) = -\sum P(x, y) \log_2 P(x, y)$$

$$= -0.45 \log_2 0.45 - 0.15 \log_2 0.15 - 0.1 \log_2 0.1 - 0.3 \log_2 0.3$$

$$\approx 1.8$$

$$3) H(X|Y) = \sum P(y) H(X|y)$$

$$H(X|Y=0) = -0.818 \log_2 0.818 - 0.182 \log_2 0.182$$

$$\approx 0.68$$

$$H(X|Y=1) = -0.333 \log_2 0.333 - 0.667 \log_2 0.667$$

$$\approx 0.92$$

$$H(X|Y) \approx 0.55 \cdot 0.68 + 0.45 \cdot 0.92$$

$$\approx 0.79$$

$$4) I(X; Y) = H(X) - H(X|Y) \approx 0.97 - 0.79 \approx 0.18$$

2-1 🧡: 대각화 (Diagonalization)의 정의와 계산 과정은 다음과 같습니다.

💡 정의: 임의의 정방행렬 A 를 고유값과 고유벡터를 통해 대각행렬의 형태로 선형 변환하는 과정이며, 이를 수식으로 표현하면 $D = P^{-1}AP$ 를 만족하는 대각행렬 D 를 찾는 것입니다. 만약 A 가 n 개의 독립인 고유벡터를 가지고 있다면 (= 가역이라면) A 는 대각화 가능하며, 이때 대각행렬의 원소는 A 의 고유값으로 구성됩니다.

💡 과정:

- 1) A 에 대한 고유값과 이에 대응하는 고유벡터를 찾은 후 각각 p_1, p_2, \dots, p_n 으로 놓습니다.
- 2) 고유벡터로 구성된 행렬 $P = [p_1, p_2, \dots, p_n]$ 을 만들고 $D = P^{-1}AP$ 을 구합니다.

다음 정방행렬을 대각화했을 때 나오는 대각행렬 D 와 고유벡터 행렬 P 를 각각 구하세요.

$$A = \begin{bmatrix} 2 & 0 & 0 \\ 1 & 2 & 1 \\ -1 & 0 & 1 \end{bmatrix}$$

$$\begin{bmatrix} 2-\lambda & 0 & 0 \\ 1 & 2-\lambda & 1 \\ -1 & 0 & 1-\lambda \end{bmatrix}$$

$$(2-\lambda)^2(1-\lambda) \Rightarrow \lambda = 1, 2$$

$$\begin{bmatrix} 0 & 0 & -1 \\ -1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$

$$D = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad P = \begin{bmatrix} -1 & 0 & 0 \\ 0 & 1 & -1 \\ 1 & 0 & 1 \end{bmatrix}$$

2-3 🧡: 특이값 분해 (SVD, Singular Value Decomposition)은 대각화와 달리 모든 크기의 행렬에 대해 적용이 가능하며, 그 계산 과정은 다음과 같습니다.

💡 1) 항상 대칭 행렬을 이루는 두 행렬 $B^T B, B B^T$ 를 계산하고, 이들의 고유값을 계산해 특이값 σ 와 고유벡터를 통해 직교대각화하여 $B^T B = V D V^T, B B^T = U D U^T$ 를 구합니다.

2) 0 이 아닌 특이값들을 내림차순으로 나열하여 Σ 를 구성하고, 이들을 모두 활용해 $A = U \Sigma V^T$ 를 구합니다.

계산 방법에 대한 구체적인 과정은 다음의 영상 자료 ([링크](#))를 반드시 참고하여 문제를 풀어주세요.

다음 행렬에 특이값 분해를 적용하였을 때 나오는 행렬 U, Σ, V^T 를 각각 구하세요.

$$B = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$B^T = \begin{bmatrix} 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \quad B = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$B^T B = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$U = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \sqrt{2} & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}, \quad V = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ 0 & 0 & 0 \end{bmatrix}$$

3-1 📌: 정규세션에서 살펴본 것과 같이, Logistic Regression 의 목적함수는 아래와 같습니다.

$$\min_w \sum_{i=1}^m \{-y^{(i)} \log(\hat{y}^{(i)}) - (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})\}$$

최적해를 구하기 위해서는 먼저 내부의 목적 함수가 convex function 인지 여부를 판단해야 합니다. 내부 목적 함수 $-y^{(i)} \log(\hat{y}^{(i)}) - (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})$ 가 convex function 임을 보이세요.

- 💡 $y^{(i)}$ 을 Logistic Function 식을 활용하면 $\hat{y}^{(i)} = \frac{1}{1 + e^{-w^T x^{(i)}}}$ 과 같이 표현할 수 있습니다.
- 💡 목적 함수를 두 부분으로 나누어서 각각 Convex 하다는 것을 증명하면 됩니다.
- 💡 convexity 를 증명하기 위해서는 w 에 대해 2 번 미분하여, 0 보다 크다는 것을 보이면 됩니다.

$$* \quad -y \log(\hat{y}) - (1-y) \log(1-\hat{y}) \quad \hat{y} = \sigma(w^T x) = \frac{1}{1 + e^{-w^T x}}$$

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

$$\frac{\partial \sigma}{\partial z} = \frac{e^{-z}}{(1 + e^{-z})^2} = \sigma(z)(1 - \sigma(z)) > 0$$

$$l(z) = -y \log \sigma(z) - (1-y) \log(1 - \sigma(z))$$

$$\frac{\partial l}{\partial z} = -y \cdot \frac{1}{\sigma(z)} \cdot \frac{\partial \sigma}{\partial z} + (1-y) \cdot \frac{1}{1 - \sigma(z)} \cdot \frac{\partial \sigma}{\partial z}$$

$$= -y \cdot (1 - \sigma(z)) + (1-y) \cdot \sigma(z)$$

$$= -y + \sigma(z)$$

$$* \quad \nabla_w l(w) = \frac{\partial l}{\partial z} \cdot \frac{\partial z}{\partial w} = (\sigma(z) - y) \cdot x$$

$$\nabla_w^2 l(w) = \frac{d}{dw} ((\sigma(z) - y) \cdot x)$$

$$= \sigma(z)(1 - \sigma(z)) \cdot x x^T \succcurlyeq 0$$

∴ convex.

3-2 🚩: Minimization 에 대한 Gradient Descent Algorithm 은 아래와 같습니다.

$$\min_{x \in X} f(x)$$

$$x_{t+1} = x_t - \gamma \nabla_x f(x_t)$$

$\nabla_x f(x_t)$: $f(x_t)$ 에 대해서 x_t 지점에서 미분한 값

다음과 같은 Loss function 과 시작점에서 $t = 2$ 일 때 나오는 값, 즉 x_2 의 값을 구하세요.

$$f(x) = x^4 - 2x^3 - 3x^2 + x$$

$$x_0 = 1, \quad \gamma = 0.2$$

$$f'(x) = 4x^3 - 6x^2 - 6x + 1$$

$$x_1 = x_0 - \gamma \cdot (4x_0^3 - 6x_0^2 - 6x_0 + 1)$$

$$= 1 - 0.2(4 - 6 - 6 + 1)$$

$$= 1 + 0.2 \times 7$$

$$= 2.4$$

$$x_2 = x_1 - \gamma(4x_1^3 - 6x_1^2 - 6x_1 + 1)$$

$$= 2.4 - 0.2(4 \times 2.4^3 - 6 \times 2.4^2 - 6 \times 2.4 + 1)$$

$$= 0.93$$

$$\therefore 0.93$$

3-3 📌: 라그랑주 승수법은 아래와 같습니다.

📌 라그랑주 승수(Lagrange Multiplier)는 제약 조건이 있는 최적화 문제를 제약 조건이 없는 문제로 변환하여 최적해를 찾기 위한 보조 변수를 말합니다. 제약 조건이 없을 때는 단순히 $\nabla f(x)=0$ 으로 최적점을 찾을 수 있지만, 제약조건 $g(x)$ 가 있을 때는 최적해는 제약을 만족하면서 $f(x)$ 를 최소화하는 지점이 되어야 합니다. 이를 위해 제약 조건과 목적함수를 결합한 새로운 함수 (Lagrangian)를 만들고, 그 stationary point 를 찾아서 목적함수 최적화와 제약 만족을 동시에 달성할 수 있습니다.

제약 조건이 있는 최적화 문제:

$$\min_x f(x) \quad \text{subject to } g(x) = 0$$

→ 이를 다음과 같은 Lagrangian 함수로 바꿉니다:

$$L(x, \lambda) = f(x) + \lambda \cdot g(x)$$

25-2 Mathematics for ML #2 세션 자료 中

사건의 λ 가 라그랑주 승수입니다. 제약조건을 penalty 처럼 반영하여 이를 만족시키는 해를 찾아낼 수 있습니다.

다음 조건을 만족하는 $f(x, y)$ 의 최솟값을 라그랑주 승수법을 이용해 구하세요.

$$\min f(x, y) = x^2 + y^2 \quad \text{s.t. } x + y \geq 2 \rightarrow 2 - x - y \leq 0$$

1) 주어진 목적 함수와 제약 조건을 이용하여 Lagrangian $L(x, y, \lambda)$ 을 설정하세요.

2) $L(x, y, \lambda)$ 을 각 변수에 대해 편미분하고, 그 값이 0이 되는 stationary point 조건을 제시하세요.

3) 위에서 얻은 조건들을 만족하는 x, y, λ 의 값을 계산하세요.

4) 구한 $f(x, y)$ 값을 목적함수 $f(x, y)$ 에 대입하여 최솟값을 계산하세요.

$$1) L(x, y, \lambda) = x^2 + y^2 + \lambda(2 - x - y)$$

$$2) \nabla_x L(x, y, \lambda) = 2x - \lambda$$

$$\nabla_y L(x, y, \lambda) = 2y - \lambda$$

$$\nabla_\lambda L(x, y, \lambda) = 2 - x - y$$

$$x = \frac{\lambda}{2}, \quad y = \frac{\lambda}{2} \rightarrow 2 - \lambda = 0 \quad \therefore \lambda = 2$$

$$3) x = 1, \quad y = 1, \quad \lambda = 2$$

$$4) L(x, y, \lambda) = 1 + 1 = 2$$