

## 25-2 DSL 정규 세션

## Mathematics for ML 과제



- 본 과제는 학회 정규 세션 「Mathematics for Machine Learning」의 내용을 다루며, 개념의 적용과 실제 활용 사례에 대한 이해를 돋기 위해 기획되었습니다. 해당 과제는 평가를 위한 것이 아니므로, 주어진 힌트(💡)를 적극 활용하시고 학회원 간 토론 및 Slack 질의응답을 적극 활용하여 해결해주십시오. 단, 답안 표절이나 LLM 의 남용은 금지합니다.
- 각 문제에서 요구하는 방법에 맞게 해결하며, 서술형 문제들은 따로 작성하시어 .pdf 파일로 답안을 작성하여 제출해 주십시오.
- 7/30 (수) 23 시 59 분까지 Github 에 .pdf 파일을 제출해 주십시오. Github 에 제출하는 방법을 모른다면 학술부 (강승우, 조지성, 한연주)로 문의 주시기 바랍니다.

## 문제 1 Entropy and Mutual Information

다음은 어느 드라마의 한 장면 중 일부입니다.

“…지는 분은 물론 벌칙이 있습니다. 아마 영화에서 보신 적이 있으실 겁니다, 러시안룰렛이라고. 이 권총에 총알 하나를 넣고 닫습니다. 그리고 지는 분 쪽으로 방아쇠를 당길 겁니다. 죽을 확률이 1/6, 살 확률은 5/6. 생각보다 나쁘지 않죠? (중략) …조금 지루한 감이 없지 않아 있네요. 그럼 이제 확률을 뒤집어 볼까요? 권총에 총알 다섯 개를 넣고 닫습니다. 확률은 1/6, 죽을 확률은 5/6. 자, 다시 시작하겠습니다.”

그러나 사실은 두 상황 모두 엔트로피의 측면에서의 지루함, 즉 불확실성은 같습니다! 총알이 발사될 확률이 각각 1/6, 5/6 인 베르누이 분포를 따르기 때문에, 엔트로피의 정의를 따라 계산하면 같은 값이 나오는 것이죠.

이 문제에서는 이처럼 주어진 사건들이 이산적인 경우 엔트로피의 성질을 알아보고, 직접 계산해보며 엔트로피와 Mutual Information 이 가진 의미를 알아보자 합니다.

1-1 💡: 주사위를 던졌을 때 나오는 눈의 사건을  $X$  라 하고, 각 눈이 나올 확률을  $p_i$  ( $0 \leq p_i \leq 1$ ,  $\sum_{i=1}^6 p_i = 1$ ) 이라 할 때, 아래의 조건에서 주사위의 엔트로피  $H(X)$ 를 각각 구하세요.  $H(X)$ 는 언제 최대가 되는지 간단한 이유 (내지는 직관)와 함께 서술하세요.

💡 엔트로피의 정의:  $H(X) = \sum_{x \in X} p(x) \log_2\{1/p(x)\} = \sum_{x \in X} -p(x) \log_2\{p(x)\}$

1) 공정한 주사위 (모든  $p_i = 1/6$ )  $H = -6 \cdot \frac{1}{6} \cdot \log_2 \frac{1}{6} = \log_2 6$

2) 모든 눈이 6 인 주사위  $P_6: 1, H = -1 \log_2 1 = 0$

3) 짹수 눈이 나올 확률이 홀수 눈이 나올 확률의 2 배인 주사위(짝수 각각 및 홀수 각각의 확률은 동일)  $P_1, P_2$

4) 1 이 나올 확률이 0.5, 나머지 눈이 나올 확률이 각각 0.1 인 주사위

$P(\text{홀수}) = 0.5, 0.5 + 0.5 = 1$

$$\begin{aligned} P_1 &= 2P_2, \quad 3P_2 + 3P_1 = 1 \\ \rightarrow P_1 &\approx \frac{1}{6}, P_2 \approx \frac{2}{6} \\ H &= \log_2 9 \end{aligned}$$

1-2 🔥: 임의의 이산확률변수  $X$ 에 대하여  $X$  가 가질 수 있는 값의 집합을  $\mathcal{X}$ 라 합시다. 예를 들어, 동전을 1회 던졌을 때의  $\mathcal{X} = \{\text{Head}, \text{Tail}\}$ 로  $|\mathcal{X}| = 2$ 입니다. 이때 엔트로피  $H(X)$ 가 가질 수 있는 값의 범위가  $0 \leq H(X) \leq \log_2 |\mathcal{X}|$ 임을 증명하세요.

- 💡 좌측 부등식의 경우, 확률 값의 성질을 활용해 증명 가능합니다.
- 💡 우측 부등식의 경우, 아래의 Jensen's Inequality를 활용해 증명 가능합니다.
  - Jensen's Inequality:  $\mathbb{E}[f(X)] \geq f(\mathbb{E}[X])$  for a convex  $f$ , and  $\mathbb{E}[f(X)] \leq f(\mathbb{E}[X])$  for a concave  $f$
  - (Bonus Question: Jensen's Inequality는 어떻게 증명할까요? Hint: 수학적 귀납법으로 n=2부터...!)

\* 드물고 빠른 즐거움

1-3 🔥: 어떤 지역 주민들의 흡연 여부 ( $X$ )와 폐암 발병 여부 ( $Y$ )에 대한 설문 조사를 실시하여 다음과 같은 결합 확률 분포를 얻었다고 가정합니다. 여기서  $X = 1$ 은 폐암 발병,  $X = 0$ 은 폐암 미발병을 의미하며,  $Y = 1$ 은 흡연,  $Y = 0$ 은 비흡연을 의미합니다. 아래 질문에 답해주세요.

$P(X, Y)$	$Y = 0$ (비흡연)	$Y = 1$ (흡연)
$X = 0$ (폐암 미발병)	0.45	0.15
$X = 1$ (폐암 발병)	0.1	0.3

1) 폐암 발병 여부  $X$  와 흡연 여부  $Y$  의 엔트로피  $H(X)$ ,  $H(Y)$ 를 계산하시오.

$$H(Y) = -0.6 \log_2 0.6 + 0.4 \log_2 0.4, \quad H(X) = -(0.45 \log_2 0.45 + 0.15 \log_2 0.15)$$

2)  $X$  와  $Y$  의 결합 엔트로피  $H(X, Y)$ 를 계산하시오.

$$H(X, Y) = -\sum P(x, y) \log_2 P(x, y) = 1.78 \text{比特}$$

3) 흡연 여부  $Y$ 에 대한 정보가 주어졌을 때, 폐암 발병 여부  $X$ 의 조건부 엔트로피  $H(X | Y)$ 를 계산하시오.

$$H(X|Y) = H(XY) - H(Y) = 0.79 \text{比特}$$

4) 폐암 발병 여부  $X$  와 흡연 여부  $Y$  의 Mutual Information  $I(X ; Y)$ 을 계산하시오.

$$I(X; Y) = H(X) - H(X|Y) = H(X) - H(Y) \sim H(X) = 0.19 \text{比特}$$

5) 4)의 결과로 나온  $I(X ; Y)$ 의 의미를 통계적 관점에서 간략하게 해석하고,

$I(X ; Y)$ 값이 0 일 경우와,  $H(X)$ 와 같을 경우 각각 어떤 의미를 갖는지 설명하시오.

💡 엔트로피 계산 시  $\log$ 의 밑은 2로 계산하면 됩니다.

💡 단위는 비트(bits)를 이용하며,  $\log$  계산 값은 근사치로만 이용하시면 됩니다.

도구

X가 1인 경우 결승

$$H(x) = -\sum_{x \in X} P(x) \log_2(P(x))$$

∴ 정의에 따른다

$$0 \leq -\sum_{x \in X} P(x) \log_2(P(x))$$

$$0 \leq P(x) \leq 1 \text{ 일 때, } \log_2(P(x)) < 0$$

$$P = (\frac{1}{2}, \frac{1}{2}), P(x), \log_2(P(x)) = (0.5, 0)$$

$$\therefore 0 \leq H(x)$$

즉, 정의에 따른다

$$-P \log_2 P = -P \cdot \frac{\ln P}{\ln 2} \quad \frac{d}{dp} \left( P \cdot \frac{\ln P}{\ln 2} \right) = \left( \frac{\ln P}{\ln 2} + P \cdot \frac{1}{P \ln 2} \right) = \left( \frac{\ln P + 1}{\ln 2} \right)$$

$$\frac{d^2}{dp^2} \left( P \cdot \frac{\ln P}{\ln 2} \right) = -\frac{1}{P \ln 2} - \frac{1}{P^2 \ln 2} \leq 0 \quad \text{이므로 } H(x) \text{는 } \frac{d}{dp} \text{에 대해 } \frac{d^2}{dp^2} < 0, \text{ convex}$$

$$\therefore E[f(x)] \leq f(E[x])$$

이제  $H(x)$ 에 대해서

$$H(x) = E(-\log_2 P(x)) = -\sum_{x \in X} P(x) \log_2 P(x)$$

$$\therefore E(-\log_2 P(x)) \leq -\log_2 E(P(x))$$

$$H(x) \leq -\log_2 E(P(x))$$

$$0 \leq H(x) \leq -\log_2 E(P(x)) \quad (P = \frac{1}{|X|})$$

$$H(x) = \sum_{x \in X} \frac{1}{|X|} \cdot \log_2 \left( \frac{1}{|X|} \right) = -|X| \cdot \frac{1}{|X|} \cdot \log_2 \left( \frac{1}{|X|} \right) \\ = \log_2 |X|$$

$$\therefore 0 \leq H(x) \leq \log_2 |X|$$

$$\therefore 0 \leq H(x) \leq \log_2(x)$$

## ④ Jensen's Inequality

선형함수와 비선형함수의 차이

$$f\left(\sum_{i=1}^n \lambda_i x_i\right) \leq \sum_{i=1}^n \lambda_i f(x_i)$$

$$\therefore n=2 \text{ 일 때}$$

$$f(\lambda_1 x_1 + \lambda_2 x_2) \leq \lambda_1 f(x_1) + \lambda_2 f(x_2) \dots \text{①}$$

$\lambda_1 + \lambda_2 = 1 \dots \text{②}$

①, ②를 더하면

$$f(\lambda_1 x_1 + (1-\lambda_1) x_2) \leq \lambda_1 f(x_1) + (1-\lambda_1) f(x_2) \text{ ③}$$

③은 Convex의 정의에 따른다

$$(f(\lambda x_1 + (1-\lambda) x_2) \leq \lambda f(x_1) + (1-\lambda) f(x_2))$$

∴ n=2 일 때

$$(i) n=k \text{ 일 때 } f\left(\sum_{i=1}^k \lambda_i x_i\right) \leq \sum_{i=1}^k \lambda_i f(x_i)$$

성립

n=k+1 일 때

$$\lambda_1 + \lambda_2 + \dots + \lambda_k = 1$$

$$\sum_{i=1}^k \frac{\lambda_i}{1-\lambda_{k+1}} = 1 \quad \text{인 경우 } 2 \text{개만$$

$$\sum_{i=1}^k \frac{\lambda_i}{1-\lambda_{k+1}} f(x_i) \geq f\left(\sum_{i=1}^k \frac{\lambda_i}{1-\lambda_{k+1}} x_i\right)$$

인 경우  $(1-\lambda_{k+1}) \frac{1}{1-\lambda_{k+1}} \neq 1, \lambda_{k+1} f(x_{k+1}) \leq f(x_{k+1})$

$$\sum_{i=1}^{k+1} \lambda_i f(x_i) \geq (1-\lambda_{k+1}) f\left(\sum_{i=1}^k \frac{\lambda_i}{1-\lambda_{k+1}} x_i\right) + \lambda_{k+1} f(x_{k+1})$$

Convex 정의에 따른다

$$f\left((1-\lambda_{k+1}) f\left(\sum_{i=1}^k \frac{\lambda_i}{1-\lambda_{k+1}} x_i\right) + \lambda_{k+1} f(x_{k+1})\right) \geq$$

$$f\left(\underbrace{(1-\lambda_{k+1}) \left(\sum_{i=1}^k \frac{\lambda_i}{1-\lambda_{k+1}} x_i\right)}_{\sum_{i=1}^k \lambda_i x_i} + \lambda_{k+1} x_{k+1}\right) = \sum_{i=1}^{k+1} \lambda_i x_i$$

$$\therefore \sum_{i=1}^{k+1} \lambda_i f(x_i) \geq f\left(\sum_{i=1}^{k+1} \lambda_i x_i\right) \therefore n=k+1 \text{ 경우 } 2 \text{ 개만$$

## 문제 2 SVD and Data Compression

선형대수학은 머신러닝과 딥러닝의 원리를 수학적으로 분석하는 과정에서 사용되는 핵심적인 내용 중 하나로, 그 중에서도 가장 중요한 개념은 바로 SVD (Singular Value Decomposition, 특이값 분해)입니다. SVD를 이해하기 위해 우선 고유값과 고유벡터를 활용한 대각화 (Diagonalization)에 대해 알아보겠습니다.

2-1 🔔: 대각화 (Diagonalization)의 정의와 계산 과정은 다음과 같습니다.

💡 정의: 임의의 정방행렬  $A$ 를 고유값과 고유벡터를 통해 대각행렬의 형태로 선형 변환하는 과정이며, 이를 수식으로 표현하면  $D = P^{-1}AP$ 를 만족하는 대각행렬  $D$ 를 찾는 것입니다. 만약  $A$ 가  $n$  개의 독립인 고유벡터를 가지고 있다면 (= 가역이라면)  $A$ 는 대각화 가능하며, 이때 대각행렬의 원소는  $A$ 의 고유값으로 구성됩니다.

💡 과정:

- 1)  $A$ 에 대한 고유값과 이에 대응하는 고유벡터를 찾은 후 각각  $p_1, p_2, \dots, p_n$ 으로 놓습니다.
- 2) 고유벡터로 구성된 행렬  $P = [p_1, p_2, \dots, p_n]$ 을 만들고  $D = P^{-1}AP$ 을 구합니다.

다음 정방행렬을 대각화했을 때 나오는 대각행렬  $D$ 와 고유벡터 행렬  $P$ 를 각각 구하세요.

$$A = \begin{bmatrix} 2 & 0 & 0 \\ 1 & 2 & 1 \\ -1 & 0 & 1 \end{bmatrix}$$

$$\det(A - \lambda I) = 0$$

$$\det(A - \lambda I) = \det \begin{bmatrix} -\lambda & 0 & -2 \\ 1 & 2-\lambda & 1 \\ 1 & 0 & -3-\lambda \end{bmatrix}$$

$$= -\lambda \cdot [(2-\lambda)(-3-\lambda) - (1 \cdot 0)] - 2 \cdot [(1 \cdot 0) - (2-\lambda)]$$

$$= -\lambda^3 + \lambda^2 + 6\lambda - 2(\lambda - 2)$$

$$= -\lambda^3 - \lambda^2 + 4\lambda + 4$$

$$\therefore \lambda = 2 \rightarrow A - \lambda I = \begin{bmatrix} -2 & 0 & -2 \\ 1 & 0 & 1 \\ 1 & 0 & -5 \end{bmatrix}$$

$$= (\lambda+1)(\lambda-2)(\lambda+2)$$

$$\therefore \lambda = -1 \rightarrow A - \lambda I = \begin{bmatrix} 1 & 0 & -2 \\ 1 & 3 & 1 \\ 1 & 0 & -2 \end{bmatrix}$$

$$\lambda = -2, -1, 2$$

$$\therefore D = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & -2 \end{bmatrix}$$

$$\therefore \lambda = -2 \rightarrow A - \lambda I = \begin{bmatrix} 2 & 0 & -2 \\ 1 & 4 & 1 \\ 1 & 0 & -1 \end{bmatrix}$$

$$P = \begin{bmatrix} 0 & 2 & 1 \\ 1 & -1 & -1 \\ 0 & 1 & 1 \end{bmatrix}$$

2-3 🔥: 특이값 분해 (SVD, Singular Value Decomposition)은 대각화와 달리 모든 크기의 행렬에 대해 적용이 가능하며, 그 계산 과정은 다음과 같습니다.

- 💡 1) 항상 대칭 행렬을 이루는 두 행렬  $B^T B, BB^T$ 를 계산하고, 이들의 고유값을 계산해 특이값  $\sigma$ 와 고유벡터를 통해 직교대각화하여  $B^T B = VDV^T, BB^T = UDU^T$ 를 구합니다.
- 2) 0 이 아닌 특이값들을 내림차순으로 나열하여  $\Sigma$ 를 구성하고, 이들을 모두 활용해  $A = U\Sigma V^T$ 를 구합니다.

계산 방법에 대한 구체적인 과정은 다음의 영상 자료 ([링크](#))를 반드시 참고하여 문제를 풀어주세요.

다음 행렬에 특이값 분해를 적용하였을 때 나오는 행렬  $U, \Sigma, V^T$ 를 각각 구하세요.

$$B = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$B^T = \begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$$

$$\sigma_1 \approx \sqrt{3}, \quad \sigma_2 \approx 1$$

$$(B^T B = \begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix})$$

$$\Sigma = \begin{bmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}$$

$$\det(B^T B - \lambda I) = 0$$

$$\det \begin{bmatrix} 2-\lambda & 1 \\ 1 & 2-\lambda \end{bmatrix} = 0$$

$$\lambda^2 - 4\lambda + 4 - 1 = 0$$

$$\lambda = 3, 1$$

$$\therefore \lambda = 3$$

$$\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0, \quad x_1 = x_2$$

$$BB^T = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 1 & 1 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$

$$\rightarrow \lambda_1 = 3, \quad \lambda_2 = 1, \quad \lambda_3 = 0$$

$$\therefore \lambda_1 = 3 \quad \begin{bmatrix} 1 & 1 & 1 \\ 1 & -2 & 0 \\ 1 & 0 & -2 \end{bmatrix} x = 0, \quad u_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

$$V_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} x = 0, \quad u_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$$

$$\therefore \lambda_2 = 1$$

$$\therefore \lambda_3 = 0$$

$$\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \quad x_1 = -x_2$$

$$\begin{bmatrix} 2 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 0 & 1 \end{bmatrix} x = 0, \quad u_3 = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ -2 \\ 1 \end{bmatrix}$$

$$V_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$V = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{6}} \\ \frac{1}{\sqrt{2}} & 0 & -\frac{2}{\sqrt{6}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{6}} \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \sqrt{3} & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}, \quad V = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

### 문제 3 Optimization Theory

최적화는 다양한 분야에서 많이 쓰이는 개념이지만, 특히 머신러닝에서는 최적의 정답을 찾기 위해 필수적으로 사용되는 개념입니다. 정규세션으로 이를 간단하게 배워보았고, 직접 수식으로 문제를 풀어보며 해당 개념을 익히고자 합니다.

3-1 🔥: 정규세션에서 살펴본 것과 같이, Logistic Regression 의 목적함수는 아래와 같습니다.

$$\min_w \sum_{i=1}^m \{-y^{(i)} \log(\hat{y}^{(i)}) - (1-y^{(i)}) \log(1-\hat{y}^{(i)})\}$$

최적해를 구하기 위해서는 먼저 내부의 목적 함수가 convex function 인지 여부를 판단해야 합니다. 내부 목적 함수  $-y^{(i)} \log(\hat{y}^{(i)}) - (1-y^{(i)}) \log(1-\hat{y}^{(i)})$  가 convex function임을 보이세요.

💡  $y^{(i)}$  을 Logistic Function 식을 활용하면  $\hat{y}^{(i)} = \frac{1}{1+e^{-w^T x^{(i)}}}$  과 같이 표현할 수 있습니다.

💡 목적 함수를 두 부분으로 나누어서 각각 Convex 하다는 것을 증명하면 됩니다.

💡 convexity 를 증명하기 위해서는 w에 대해 2 번 미분하여, 0 보다 크다는 것을 보이면 됩니다.

$$z = w^T x, \hat{y} = g(z) = \frac{1}{1+e^{-z}}, l(z; y) = -[y \log \hat{y} + (1-y) \log(1-\hat{y})]$$

$l(z; y)$ 은 모형의 손실함수  $\rightarrow$  Convex.

$$l(z; y) = y l(z; 1) + (1-y) l(z; 0) \leq \text{Convex}, l(w^T x; y) \text{ Convex}$$

3-2 🔥: Minimization에 대한 Gradient Descent Algorithm은 아래와 같습니다.

$$\min_{x \in X} f(x)$$

$$x_{t+1} = x_t - \gamma \nabla_x f(x_t)$$

$\nabla_x f(x_t)$ :  $f(x_t)$ 에 대해서  $x_t$  지점에서 미분한 값

다음과 같은 Loss function과 시작점에서  $t=2$  일 때 나오는 값, 즉  $x_2$ 의 값을 구하세요.

$$f(x) = x^4 - 2x^3 - 3x^2 + x \rightarrow f(x) = 4x^3 - 6x^2 - 6x + 1$$

$$x_0 = 1, \quad \gamma = 0.2 \quad x_{t+1} = x_t - \gamma \nabla_x f(x_t)$$

$$\text{Step 1: } f(x) = 4 \cdot 1 - 6 \cdot 1 - 6 \cdot 1 + 1 \rightarrow 7, \quad x_1 = 2.4$$

$$\text{Step 2: } f(x) = 4(2.4)^3 - 6(2.4)^2 - 6(2.4) + 1 = 7.34, \quad x_2 \approx 2.93$$

### 3-3 🌟: 라그랑주 승수법은 아래와 같습니다.

💡 라그랑주 승수(Lagrange Multiplier)는 제약 조건이 있는 최적화 문제를 제약 조건이 없는 문제로 변환하여 최적해를 찾기 위한 보조 변수를 말합니다. 제약 조건이 없을 때는 단순히  $\nabla f(x)=0$  으로 최적점을 찾을 수 있지만, 제약조건  $g(x)$ 가 있을 때는 최적해는 제약을 만족하면서  $f(x)$ 를 최소화하는 지점이 되어야 합니다. 이를 위해 제약 조건과 목적함수를 결합한 새로운 함수 (lagrangian)을 만들고, 그 stationary point 를 찾아서 목적함수 최적화와 제약 만족을 동시에 달성할 수 있습니다.

제약 조건이 있는 최적화 문제:

$$\min_x f(x) \quad \text{subject to } g(x) = 0$$

→ 이를 다음과 같은 Lagrangian 함수로 바꿉니다:

$$L(x, \lambda) = f(x) + \lambda \cdot g(x)$$

25-2 Mathematics for ML #2 세션 자료 中

사진의  $\lambda$ 가 라그랑주 승수입니다. 제약조건을 penalty 처럼 반영하여 이를 만족시키는 해를 찾아낼 수 있습니다.

다음 조건을 만족하는  $f(x, y)$ 의 최솟값을 라그랑주 승수법을 이용해 구하세요.

$$\min f(x, y) = x^2 + y^2 \quad \text{s.t. } x + y \geq 2$$

1) 주어진 목적 함수와 제약 조건을 이용하여 lagrangian  $L(x, y, \lambda)$ 을 설정하세요.

$$L(x, y, \lambda) = x^2 + y^2 - \lambda(x + y - 2) \quad (\lambda \geq 0)$$

2)  $L(x, y, \lambda)$ 을 각 변수에 대해 편미분하고, 그 값이 0 이 되는 stationary point 조건을 제시하세요.

$$\frac{\partial L}{\partial x} = 2x - \lambda = 0, \quad \frac{\partial L}{\partial y} = 2y - \lambda = 0 \quad x = \lambda, \quad y = \lambda$$

3) 위에서 얻은 조건들을 만족하는  $x, y, \lambda$  의 값을 계산하세요.

$$x + y - 2 \geq 0, \quad x = \lambda, \quad y = \lambda \quad \lambda \geq 0, \quad \lambda(x + y - 2) = 0 \quad \lambda = 1, \quad x = 1, \quad y = 1$$

4) 구한  $f(x, y)$ 값을 목적함수  $f(x, y)$ 에 대입하여 최솟값을 계산하세요.

$$f(1, 1) = 1^2 + 1^2 = 2$$

#### Reference

- 24-1 기초과제 2 (10 기 신재우)
- 24-2 기초과제 (11 기 김현진, 김정우)
- 25-1 Mathematics for ML 과제 (12 기 김민규)
- Information Theory for Data Science, Prof. Son, Fall 2024, Yonsei Univ.

#### Data Science Lab

담당자: 13 기 조지성  
[xiwang01@yonsei.ac.kr](mailto:xiwang01@yonsei.ac.kr)