

25-2 DSL 정규 세션

Mathematics for ML 과제

- 본 과제는 학회 정규 세션 「Mathematics for Machine Learning」의 내용을 다루며, 개념의 적용과 실제 활용 사례에 대한 이해를 돋기 위해 기획되었습니다. 해당 과제는 평가를 위한 것이 아니므로, 주어진 힌트(💡)를 적극 활용하시고 학회원 간 토론 및 Slack 질의응답을 적극 활용하여 해결해주십시오. **단, 답안 표절이나 LLM 의 남용은 금지합니다.**
- 각 문제에서 요구하는 방법에 맞게 해결하며, 서술형 문제들은 따로 작성하시어 .pdf 파일로 답안을 작성하여 제출해 주십시오.
- 7/30 (수) 23 시 59 분까지 Github 에 .pdf 파일을 제출해 주십시오. Github 에 제출하는 방법을 모른다면 학술부 (강승우, 조지성, 한연주)로 문의 주시기 바랍니다.

문제 1 Entropy and Mutual Information

다음은 어느 드라마의 한 장면 중 일부입니다.

“…지는 분은 물론 벌칙이 있습니다. 아마 영화에서 보신 적이 있으실 겁니다, 러시안룰렛이라고. 이 권총에 총알 하나를 넣고 닫습니다. 그리고 지는 분 쪽으로 방아쇠를 당길 겁니다. 죽을 확률이 1/6, 살 확률은 5/6. 생각보다 나쁘지 않죠? (중략) …조금 지루한 감이 없지 않아 있네요. 그럼 이제 확률을 뒤집어 볼까요? 권총에 총알 다섯 개를 넣고 닫습니다. 확률은 1/6, 죽을 확률은 5/6. 자, 다시 시작하겠습니다.”

그러나 사실은 두 상황 모두 엔트로피의 측면에서의 지루함, 즉 불확실성은 같습니다! 총알이 발사될 확률이 각각 1/6, 5/6 인 베르누이 분포를 따르기 때문에, 엔트로피의 정의를 따라 계산하면 같은 값이 나오는 것이죠.

이 문제에서는 이처럼 주어진 사건들이 이산적인 경우 엔트로피의 성질을 알아보고, 직접 계산해보며 엔트로피와 Mutual Information 이 가진 의미를 알아보고자 합니다.

1-1 💡: 주사위를 던졌을 때 나오는 눈의 사건을 X 라 하고, 각 눈이 나올 확률을 p_i ($0 \leq p_i \leq 1$, $\sum_{i=1}^6 p_i = 1$) 이라 할 때, 아래의 조건에서 주사위의 엔트로피 $H(X)$ 를 각각 구하세요. $H(X)$ 는 언제 최대가 되는지 간단한 이유 (내지는 직관)와 함께 서술하세요.

💡 엔트로피의 정의: $H(X) = \sum_{x \in X} p(x) \log_2 \{1/p(x)\} = \sum_{x \in X} -p(x) \log_2 \{p(x)\}$

1) 공정한 주사위 (모든 $p_i = 1/6$)

2) 모든 눈이 6 인 주사위

3) 짹수 눈이 나올 확률이 홀수 눈이 나올 확률의 2 배인 주사위(짝수 각각 및 홀수 각각의 확률은 동일)

4) 1 이나 나올 확률이 0.5, 나머지 눈이 나올 확률이 각각 0.1 인 주사위

$$(1) H(X) = \sum_{i=1}^6 -\frac{1}{6} \log_2 \frac{1}{6} = \log_2 6$$

$$(2) P_1 \sim P_5 = 0 \quad P_6 = 1$$

$$H(X) = -1 \cdot \log_2 1 = 0$$

$$(3) P_1 = P_3 = P_5 = 2P \quad P_2 = P_4 = P_6 = P$$

$$6P + 3P = 1 \quad 9P = 1 \quad P = \frac{1}{9}$$

$$P_1 = P_3 = P_5 = \frac{2}{9} \quad P_2 = P_4 = P_6 = \frac{1}{9}$$

$$H(X) = -\frac{6}{9} \log_2 \frac{2}{9} - \frac{3}{9} \log_2 \frac{1}{9}$$

$$= -\frac{2}{3} \log_2 \frac{2}{9} - \frac{1}{3} \log_2 \frac{1}{9}$$

$$(4) H(X) = -\frac{1}{2} \log_2 \frac{1}{2} - \frac{5}{10} \log_2 \frac{1}{10}$$

$$= \frac{1}{2} - \frac{1}{2} \log_2 \frac{1}{10} = \frac{1}{2} \log_2 20$$

1-2 🔥: 임의의 이산확률변수 X 에 대하여 X 가 가질 수 있는 값의 집합을 \mathcal{X} 라 합시다. 예를 들어, 동전을 1회 던졌을 때의 $\mathcal{X} = \{\text{Head}, \text{Tail}\}$ 로 $|\mathcal{X}| = 2$ 입니다. 이때 엔트로피 $H(X)$ 가 가질 수 있는 값의 범위가 $0 \leq H(X) \leq \log_2 |\mathcal{X}|$ 임을 증명하세요.

💡 좌측 부등식의 경우, 확률 값의 성질을 활용해 증명 가능합니다.

💡 우측 부등식의 경우, 아래의 Jensen's Inequality를 활용해 증명 가능합니다.

- Jensen's Inequality: $\mathbb{E}[f(X)] \geq f(\mathbb{E}[X])$ for a convex f , and $\mathbb{E}[f(X)] \leq f(\mathbb{E}[X])$ for a concave f

(Bonus Question: Jensen's Inequality는 어떻게 증명할까요? Hint: 수학적 귀납법으로 n=2부터...!)

$$0 \leq P(\mathcal{A}) \leq 1 \rightarrow \log_2 P(\mathcal{A}) \leq 0 \rightarrow -\log_2 P(\mathcal{A}) \geq 0$$

$$\underline{P(\mathcal{A}) \geq 0} \quad \downarrow$$

$$-\underline{P(\mathcal{A}) \log_2 P(\mathcal{A}) \geq 0} \quad \leftarrow$$

$$H(\mathcal{A}) \geq 0$$

$$H(\mathcal{A}) = -\sum P(\mathcal{A}) \log_2 P(\mathcal{A})$$

균등분포 가정 (이때 엔트로피가 최대일 것이기 때문)

$$P(\mathcal{A}) = \frac{1}{|\mathcal{A}|}$$

$H(\mathcal{A})$ 의 상한값

$$H(\mathcal{A}) = -\sum \frac{1}{|\mathcal{A}|} \log_2 \frac{1}{|\mathcal{A}|} = \log_2 |\mathcal{A}|$$

$$H(\mathcal{A}) \leq \log_2 |\mathcal{A}|$$

1-3 🔥: 어떤 지역 주민들의 흡연 여부 (X)와 폐암 발병 여부 (X)에 대한 설문 조사를 실시하여 다음과 같은 결합 확률 분포를 얻었다고 가정합니다. 여기서 $X = 1$ 은 폐암 발병, $X = 0$ 은 폐암 미발병을 의미하며, $Y = 1$ 은 흡연, $Y = 0$ 은 비흡연을 의미합니다. 아래 질문에 답주세요.

$P(X, Y)$	$Y = 0$ (비흡연)	$Y = 1$ (흡연)
$X = 0$ (폐암 미발병)	0.45	0.15
$X = 1$ (폐암 발병)	0.1	0.3

1) 폐암 발병 여부 X 와 흡연 여부 Y 의 엔트로피 $H(X)$, $H(Y)$ 를 계산하시오.

2) X 와 Y 의 결합 엔트로피 $H(X, Y)$ 를 계산하시오.

3) 흡연 여부 Y 에 대한 정보가 주어졌을 때, 폐암 발병 여부 X 의 조건부 엔트로피 $H(X | Y)$ 를 계산하시오.

4) 폐암 발병 여부 X 와 흡연 여부 Y 의 Mutual Information $I(X ; Y)$ 를 계산하시오.

5) 4)의 결과로 나온 $I(X ; Y)$ 의 의미를 통계적 관점에서 간략하게 해석하고,
 $I(X ; Y)$ 값이 0 일 경우와, $H(X)$ 와 같을 경우 각각 어떤 의미를 갖는지 설명하시오.

💡 엔트로피 계산 시 \log 의 밑은 2로 계산하면 됩니다.

💡 단위는 비트(bits)를 이용하며, \log 계산 값은 근사치로만 이용하시면 됩니다.

(1)

$$H(X) = -0.6 \log_2 0.6 - 0.4 \log_2 0.4 \\ = 0.442 + 0.529 = 0.971$$

$$H(Y) = -0.55 \log_2 0.55 - 0.45 \log_2 0.45 \\ = 0.494 + 0.518 = 0.992$$

(2)

$$H(X, Y) = -0.45 \log_2 0.45 - 0.15 \log_2 0.15 - 0.1 \log_2 0.1 - 0.3 \log_2 0.3 \\ = 0.518 + 0.411 + 0.332 + 0.521 \\ = 1.782$$

$$(3) H(X|Y) = H(X, Y) - H(Y)$$

$$= 1.782 - 0.992 = 0.79$$

$$(4) I(X; Y) = H(X) - H(X|Y)$$

$$= 0.971 - 0.79 = 0.181$$

(5) 작은 값이기 때문에, 흡연 여부와 폐암 여부가 공유하는 정보량이 작다

$I(X; Y) = 0$: 흡연 여부와 폐암 여부는 아무 관련 X

$I(X; Y) = H(X)$: $H(X|Y)$ 가 0이라는 말이기 때문에 Y를 알더라도 X에 대한 정보량에는 변함이 없음

문제 2 SVD and Data Compression

선형대수학은 머신러닝과 딥러닝의 원리를 수학적으로 분석하는 과정에서 사용되는 핵심적인 내용 중 하나로, 그 중에서도 가장 중요한 개념은 바로 SVD (Singular Value Decomposition, 특이값 분해)입니다. SVD를 이해하기 위해 우선 고유값과 고유벡터를 활용한 대각화 (Diagonalization)에 대해 알아보겠습니다.

2-1 🔥: 대각화 (Diagonalization)의 정의와 계산 과정은 다음과 같습니다.

💡 정의: 임의의 정방행렬 A 를 고유값과 고유벡터를 통해 대각행렬의 형태로 선형 변환하는 과정이며, 이를 수식으로 표현하면 $D = P^{-1}AP$ 를 만족하는 대각행렬 D 를 찾는 것입니다. 만약 A 가 n 개의 독립인 고유벡터를 가지고 있다면 (= 가역이라면) A 는 대각화 가능하며, 이때 대각행렬의 원소는 A 의 고유값으로 구성됩니다.

💡 과정:

- 1) A 에 대한 고유값과 이에 대응하는 고유벡터를 찾은 후 각각 p_1, p_2, \dots, p_n 으로 놓습니다.
- 2) 고유벡터로 구성된 행렬 $P = [p_1, p_2, \dots, p_n]$ 을 만들고 $D = P^{-1}AP$ 을 구합니다.

다음 정방행렬을 대각화했을 때 나오는 대각행렬 D 와 고유벡터 행렬 P 를 각각 구하세요.

$$A = \begin{bmatrix} 2 & 0 & 0 \\ 1 & 2 & 1 \\ -1 & 0 & 1 \end{bmatrix}$$

$$A - \lambda I = \begin{bmatrix} 2-\lambda & 0 & 0 \\ 1 & 2-\lambda & 1 \\ -1 & 0 & 1-\lambda \end{bmatrix} \quad \det(A - \lambda I) = (2-\lambda)(2-\lambda)(1-\lambda) = (2-\lambda)^2(1-\lambda) \rightarrow \lambda_1=1, \lambda_2=\lambda_3=2$$

$$\lambda_1 = 1 \quad \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ -1 & 0 & 0 \end{bmatrix} \begin{bmatrix} \lambda_1 \\ \lambda_2 \\ \lambda_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \quad \lambda_1 = 0 \quad \lambda_1 + \lambda_2 + \lambda_3 = 0 \quad \lambda_3 = 0 \quad P_1 = \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix} \quad P = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \\ -1 & -1 & 0 \end{bmatrix}$$

$$\lambda_2 = \lambda_3 = 2 \quad \begin{bmatrix} 0 & 0 & 0 \\ 1 & 0 & 1 \\ -1 & 0 & -1 \end{bmatrix} \begin{bmatrix} \lambda_1 \\ \lambda_2 \\ \lambda_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \quad \lambda_1 + \lambda_3 = 0 \quad P_2 = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix} \quad P_3 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \quad D = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

2-3 🔥: 특이값 분해 (SVD, Singular Value Decomposition)은 대각화와 달리 모든 크기의 행렬에 대해 적용이 가능하며, 그 계산 과정은 다음과 같습니다.

- 1) 항상 대칭 행렬을 이루는 두 행렬 $B^T B, BB^T$ 를 계산하고, 이들의 고유값을 계산해 특이값 σ 와 고유벡터를 통해 직교대각화하여 $B^T B = V D V^T, BB^T = U D U^T$ 를 구합니다.
- 2) 0이 아닌 특이값들을 내림차순으로 나열하여 Σ 를 구성하고, 이들을 모두 활용해 $A = U \Sigma V^T$ 를 구합니다.

계산 방법에 대한 구체적인 과정은 다음의 영상 자료 ([링크](#))를 반드시 참고하여 문제를 풀어주세요.

다음 행렬에 특이값 분해를 적용하였을 때 나오는 행렬 U, Σ, V^T 를 각각 구하세요.

$$B = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$B^T B = \begin{bmatrix} 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$\begin{vmatrix} 1-\lambda & 1 & 0 \\ 1 & 1-\lambda & 0 \\ 0 & 0 & 1-\lambda \end{vmatrix} = (1-\lambda) \begin{vmatrix} 1-\lambda & 1 & 0 \\ 1 & 1-\lambda & 0 \\ 0 & 0 & 1-\lambda \end{vmatrix} = (1-\lambda)(1-2\lambda+\lambda^2-1) = (1-\lambda)(\lambda^2-2\lambda) = (1-\lambda)\lambda(\lambda-2)$$

$$\lambda_1=2 \quad \lambda_2=1 \quad \lambda_3=0$$

$$G_1=\sqrt{2} \quad G_2=1$$

$$\begin{bmatrix} -1 & 1 & 0 \\ 1 & -1 & 0 \\ 0 & 0 & -1 \end{bmatrix} \begin{bmatrix} \lambda_1 \\ \lambda_2 \\ \lambda_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$\begin{aligned} -\lambda_1 + \lambda_2 &= 0 \\ \lambda_1 - \lambda_2 &= 0 \\ -\lambda_3 &= 0 \end{aligned}$$

$$W_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}$$

$$V_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}$$

$$\lambda_2=1$$

$$\begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \lambda_1 \\ \lambda_2 \\ \lambda_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$\begin{aligned} \lambda_1 &= 0 \\ \lambda_2 &= 0 \\ \lambda_3 &= 0 \end{aligned}$$

$$W_2 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

$$V_2 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

$$\lambda_3=0$$

$$\begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \lambda_1 \\ \lambda_2 \\ \lambda_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$\begin{aligned} \lambda_1 &= -\lambda_2 \\ \lambda_3 &= 0 \end{aligned}$$

$$W_3 = \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}$$

$$V_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}$$

$$V = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \end{bmatrix}$$

$$V' = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ 0 & 0 & 1 \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \end{bmatrix}$$

$$Z = \begin{bmatrix} \sqrt{2} & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$

$$U_1 = \frac{1}{G_1} B V_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \\ 0 \end{bmatrix} = \frac{1}{2} \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} = \frac{1}{2} \begin{bmatrix} 2 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$$

$$U_2 = \frac{1}{G_2} B V_2 = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

$$U = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$B = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \sqrt{2} & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ 0 & 0 & 1 \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \end{bmatrix}$$

U

Z

V'

3-1 🔥: 정규세션에서 살펴본 것과 같이, Logistic Regression의 목적함수는 아래와 같습니다.

$$\min_w \sum_{i=1}^m \{-y^{(i)} \log(\hat{y}^{(i)}) - (1-y^{(i)}) \log(1-\hat{y}^{(i)})\}$$

최적해를 구하기 위해서는 먼저 내부의 목적 함수가 convex function인지 여부를 판단해야 합니다. 내부 목적 함수 $-y^{(i)} \log(\hat{y}^{(i)}) - (1-y^{(i)}) \log(1-\hat{y}^{(i)})$ 가 convex function임을 보이세요.

💡 $y^{(i)}$ 을 Logistic Function 식을 활용하면 $\hat{y}^{(i)} = \frac{1}{1+e^{-w^T x^{(i)}}}$ 과 같이 표현할 수 있습니다.

💡 목적 함수를 두 부분으로 나누어서 각각 Convex하다는 것을 증명하면 됩니다.

💡 convexity를 증명하기 위해서는 w 에 대해 2번 미분하여, 0보다 크다는 것을 보이면 됩니다.

$$\hat{y}^{(i)} = \frac{1}{1+e^{-w^T x^{(i)}}} \quad 1-\hat{y} = \frac{e^{-w^T x^{(i)}}}{1+e^{-w^T x^{(i)}}}$$

$$\begin{aligned} J(w) &= -y^{(i)} \times \log\left(\frac{1}{1+e^{-w^T x^{(i)}}}\right) - (1-y^{(i)}) \log\left(\frac{e^{-w^T x^{(i)}}}{1+e^{-w^T x^{(i)}}}\right) \\ &= y^{(i)} \log(1+e^{-w^T x^{(i)}}) - (1-y^{(i)}) \{ -w^T x^{(i)} - \log(1+e^{-w^T x^{(i)}}) \} \\ &= \underbrace{\log(1+e^{-w^T x^{(i)}})}_{g(w)} + \underbrace{(1-y^{(i)}) w^T x^{(i)}}_{h(w)} \end{aligned}$$

$$g(w) = \frac{-e^{-w^T x^{(i)}}}{1+e^{-w^T x^{(i)}}} \times x^{(i)}$$

$$a(z) = \frac{-e^{-z}}{1+e^{-z}} \quad z = w^T x^{(i)}$$

$$\frac{da}{dz} = \frac{e^{-z}(1+e^{-z}) + e^{-z} \times (-e^{-z})}{(1+e^{-z})^2} = \frac{e^{-z}}{(1+e^{-z})^2}$$

$$\frac{dz}{dw} = x^{(i)}$$

$$\frac{da}{dw} = \frac{e^{-z}}{(1+e^{-z})^2} \times x^{(i)} = \frac{-e^{-w^T x^{(i)}}}{(1+e^{-w^T x^{(i)}})^2} \times x^{(i)}$$

$$g''(w) = \frac{-e^{-w^T x^{(i)}}}{(1+e^{-w^T x^{(i)}})^2} \times x^{(i)} x^{(i)T}$$

$$= \sigma(w^T x^{(i)}) \times (1 - \sigma(w^T x^{(i)})) \times x^{(i)} x^{(i)T}$$

$$\geq 0$$

PSD

→ convex하다

3-2 🔥: Minimization에 대한 Gradient Descent Algorithm은 아래와 같습니다.

$$\min_{x \in X} f(x)$$

$$x_{t+1} = x_t - \gamma \nabla_x f(x_t)$$

$\nabla_x f(x_t)$: $f(x_t)$ 에 대해서 x_t 지점에서 미분한 값

다음과 같은 Loss function과 시작점에서 $t = 2$ 일 때 나오는 값, 즉 x_2 의 값을 구하세요.

$$f(x) = x^4 - 2x^3 - 3x^2 + x$$

$$x_0 = 1, \quad \gamma = 0.2$$

$$f'(x) = 4x^3 - 6x^2 - 6x + 1$$

$$x_1 = 1 - 0.2 \times f'(1) = 1 - 0.2 \times (-7) = 1 + 1.4 = 2.4$$

$$\begin{aligned} x_2 &= 2.4 - 0.2 f'(2.4) = 2.4 - 0.2 \times (4 \times (3.824 - 6 \times 5.76 - 6 \times 2.4 + 1)) \\ &= 2.4 - 0.2 \times (55.296 - 34.56 - 14.4 + 1) \\ &= 2.4 - 0.2 \times 7.336 \\ &= 2.4 - 1.467 = 0.933 \end{aligned}$$

3-3 🔥: 라그랑주 승수법은 아래와 같습니다.

💡 라그랑주 승수(Lagrange Multiplier)는 제약 조건이 있는 최적화 문제를 제약 조건이 없는 문제로 변환하여 최적해를 찾기 위한 보조 변수를 말합니다. 제약 조건이 없을 때는 단순히 $\nabla f(x) = 0$ 으로 최적점을 찾을 수 있지만, 제약조건 $g(x)$ 가 있을 때는 최적하는 제약을 만족하면서 $f(x)$ 를 최소화하는 지점이 되어야 합니다. 이를 위해 제약 조건과 목적함수를 결합한 새로운 함수(lagrangian)을 만들고, 그 stationary point를 찾아서 목적함수 최적화와 제약 만족을 동시에 달성할 수 있습니다.

제약 조건이 있는 최적화 문제:

$$\min_x f(x) \quad \text{subject to } g(x) = 0$$

→ 이를 다음과 같은 Lagrangian 함수로 바꿉니다:

$$L(x, \lambda) = f(x) + \lambda \cdot g(x)$$

25-2 Mathematics for ML #2 세션 자료 中

사진의 λ 가 라그랑주 승수입니다. 제약조건을 penalty 처럼 반영하여 이를 만족시키는 해를 찾아낼 수 있습니다.

다음 조건을 만족하는 $f(x, y)$ 의 최솟값을 라그랑주 승수법을 이용해 구하세요.

$$\min f(x, y) = x^2 + y^2 \quad s.t. \quad x + y \geq 2$$

1) 주어진 목적 함수와 제약 조건을 이용하여 lagrangian $L(x, y, \lambda)$ 을 설정하세요.

2) $L(x, y, \lambda)$ 을 각 변수에 대해 편미분하고, 그 값이 0이 되는 stationary point 조건을 제시하세요.

3) 위에서 얻은 조건들을 만족하는 x, y, λ 의 값을 계산하세요.

4) 구한 $f(x, y)$ 값을 목적함수 $f(x, y)$ 에 대입하여 최솟값을 계산하세요.

$$(1) L(x, y, \lambda) = x^2 + y^2 + \lambda(x + y - 2)$$

$$(2) \frac{\partial L}{\partial x} = 2x + \lambda = 0 \quad 2x = -\lambda$$

$$\frac{\partial L}{\partial y} = 2y + \lambda = 0 \quad 2y = -\lambda$$

$$\frac{\partial L}{\partial \lambda} = x + y - 2 = 0 \quad x + y = 2$$

$$(3) x = y, x + y = 2 \quad x = 1, y = 1, \lambda = -2$$

$$(4) f(x, y) = 1 + 1 = 2$$