

## 25-2 DSL 정규 세션

## Mathematics for ML 과제



- 본 과제는 학회 정규 세션 「Mathematics for Machine Learning」의 내용을 다루며, 개념의 적용과 실제 활용 사례에 대한 이해를 돋기 위해 기획되었습니다. 해당 과제는 평가를 위한 것이 아니므로, 주어진 힌트(💡)를 적극 활용하시고 학회원 간 토론 및 Slack 질의응답을 적극 활용하여 해결해주십시오. 단, 답안 표절이나 LLM 의 남용은 금지합니다.
- 각 문제에서 요구하는 방법에 맞게 해결하며, 서술형 문제들은 따로 작성하시어 .pdf 파일로 답안을 작성하여 제출해 주십시오.
- 7/30 (수) 23 시 59 분까지 Github 에 .pdf 파일을 제출해 주십시오. Github 에 제출하는 방법을 모른다면 학술부 (강승우, 조지성, 한연주)로 문의 주시기 바랍니다.

## 문제 1 Entropy and Mutual Information

다음은 어느 드라마의 한 장면 중 일부입니다.

“…지는 분은 물론 벌칙이 있습니다. 아마 영화에서 보신 적이 있으실 겁니다, 러시안룰렛이라고. 이 권총에 총알 하나를 넣고 닫습니다. 그리고 지는 분 쪽으로 방아쇠를 당길 겁니다. 죽을 확률이 1/6, 살 확률은 5/6. 생각보다 나쁘지 않죠? (중략) …조금 지루한 감이 없지 않아 있네요. 그럼 이제 확률을 뒤집어 볼까요? 권총에 총알 다섯 개를 넣고 닫습니다. 확률은 1/6, 죽을 확률은 5/6. 자, 다시 시작하겠습니다.”

그러나 사실은 두 상황 모두 엔트로피의 측면에서의 지루함, 즉 불확실성은 같습니다! 총알이 발사될 확률이 각각 1/6, 5/6 인 베르누이 분포를 따르기 때문에, 엔트로피의 정의를 따라 계산하면 같은 값이 나오는 것이죠.

이 문제에서는 이처럼 주어진 사건들이 이산적인 경우 엔트로피의 성질을 알아보고, 직접 계산해보며 엔트로피와 Mutual Information 이 가진 의미를 알아보자 합니다.

1-1 💡: 주사위를 던졌을 때 나오는 눈의 사건을 X 라 하고, 각 눈이 나올 확률을  $p_i$  ( $0 \leq p_i \leq 1$ ,  $\sum_{i=1}^6 p_i = 1$ ) 이라 할 때, 아래의 조건에서 주사위의 엔트로피  $H(X)$ 를 각각 구하세요.  $H(X)$ 는 언제 최대가 되는지 간단한 이유 (내지는 직관)와 함께 서술하세요.

💡 엔트로피의 정의:  $H(X) = \sum_{x \in X} p(x) \log_2 \{1/p(x)\} = \sum_{x \in X} -p(x) \log_2 \{p(x)\}$

$$\begin{aligned} 1) \text{ 공정한 주사위 } (\text{모든 } p_i = 1/6) \quad H(X) &= -\sum_{i=1}^6 \frac{1}{6} \log_2 \left(\frac{1}{6}\right) \\ &= -6 \times \frac{1}{6} \log_2 \left(\frac{1}{6}\right) = -\log_2 \left(\frac{1}{6}\right) = \log_2 6 \end{aligned}$$

2) 모든 눈이 6인 주사위 눈이 6이 나올 확률은 1, 나머지 눈이 나올 확률은 0.

$$H(X) = -\log_2 1$$

3) 짹수 눈이 나올 확률이 홀수 눈이 나올 확률의 2 배인 주사위(짝수 각각 및 홀수 각각의 확률은 동일)

4) 1이 나올 확률이 0.5, 나머지 눈이 나올 확률이 각각 0.1인 주사위

$$H(X) = -\left(\frac{1}{2} \times \log_2 \frac{1}{2} + 5 \times \frac{1}{10} \times \log_2 \frac{1}{10}\right) = -\left(\frac{1}{2} + \frac{1}{2} \log_2 10\right)$$

⇒ 엔트로피는 1인 경우 (정량한 정보)에 uniform distribution일 때, 최대가 된다.

1-2 🌟 : 임의의 이산확률변수  $X$ 에 대하여  $X$  가 가질 수 있는 값의 집합을  $\mathcal{X}$ 라 합시다. 예를 들어, 동전을 1회 던졌을 때의  $\mathcal{X} = \{\text{Head}, \text{Tail}\}$ 로  $|\mathcal{X}| = 2$ 입니다. 이때 엔트로피  $H(X)$ 가 가질 수 있는 값의 범위가  $0 \leq H(X) \leq \log_2 |\mathcal{X}|$ 임을 증명하세요.

💡 좌측 부등식의 경우, 확률 값의 성질을 활용해 증명 가능합니다.

💡 우측 부등식의 경우, 아래의 Jensen's Inequality를 활용해 증명 가능합니다.

- Jensen's Inequality:  $\mathbb{E}[f(X)] \geq f(\mathbb{E}[X])$  for a convex  $f$ , and  $\mathbb{E}[f(X)] \leq f(\mathbb{E}[X])$  for a concave  $f$
- (Bonus Question: Jensen's Inequality는 어떻게 증명할까요? Hint: 수학적 귀납법으로 n=2부터...!)

①  $0 \leq H(X)$  증명.

$P(x)$ 는 확률이기 때문에,  $0 \leq P(x) \leq 1$

$$\therefore \log_2 P(x) < 0, -\log_2 P(x) > 0$$

$$H(X) = -\sum p(x) \log_2 p(x) \geq 0.$$

$$-P(x) \times \log_2 P(x) > 0 \quad \therefore H(X) > 0$$

$P(x)=1$ 인 경우,  $H(X)=0$ 이 되기 때문이다.

증명마저  $0 \leq H(X)$ .

②  $H(X) \leq \log_2 |\mathcal{X}|$  증명

$$H(X) = \sum p(x) \log_2 \frac{1}{p(x)}$$

$f(x) = \log_2(x)$ 은 concave 함수. 반례가  $\frac{1}{p(x)}$

$$\therefore E[f(x)] \leq f(E[x])$$

cf) 가중평균 정의:  $E[x] = \sum_x p(x)x$

$$E(f(x)) = \sum_x p(x)f(x)$$

∴ 대입하면,  $\sum_x p(x) \log_2 \frac{1}{p(x)} \leq \log_2 (\sum_x p(x)x)$

$$E\left[\frac{1}{p(x)}\right] = \sum_x p(x) \cdot \frac{1}{p(x)} = |\mathcal{X}|$$

$$E\left(\frac{1}{p(x)}\right) = \sum_x p(x) \cdot \frac{1}{p(x)} = |\mathcal{X}| \quad \therefore H(X) \leq f(p(x)) \quad H(X) \leq \log_2 |\mathcal{X}|$$

1-3 🌟 : 어떤 지역 주민들의 흡연 여부 ( $X$ )와 폐암 발병 여부 ( $Y$ )에 대한 설문 조사를 실시하여 다음과 같은 결합 확률 분포를 얻었다고 가정합니다. 여기서  $X = 1$ 은 폐암 발병,  $X = 0$ 은 폐암 미발병을 의미하며,  $Y = 1$ 은 흡연,  $Y = 0$ 은 비흡연을 의미합니다. 아래 질문에 답해주세요.

$P(X, Y)$	$Y = 0$ (비흡연)	$Y = 1$ (흡연)
$X = 0$ (폐암 미발병)	0.45	0.15
$X = 1$ (폐암 발병)	0.1	0.3

1) 폐암 발병 여부  $X$ 와 흡연 여부  $Y$ 의 엔트로피  $H(X)$ ,  $H(Y)$ 를 계산하시오.

$$\textcircled{1} H(X) = -0.6 \log_2 0.6 - 0.4 \log_2 0.4 = 0.971 \text{ bits} \quad \textcircled{2} H(Y) = -0.55 \log_2 0.55 - 0.45 \log_2 0.45 = 0.996 \text{ bits}$$

2)  $X$  와  $Y$ 의 결합 엔트로피  $H(X, Y)$ 를 계산하시오.

$$H(X, Y) = -\sum_x \sum_y P(x, y) \log_2 P(x, y) = -[0.45 \log_2 0.45 + 0.15 \log_2 0.15 + 0.1 \log_2 0.1 + 0.3 \log_2 0.3] = 1.782 \text{ bits}$$

3) 흡연 여부  $Y$ 에 대한 정보가 주어졌을 때, 폐암 발병 여부  $X$ 의 조건부 엔트로피  $H(X | Y)$ 를 계산하시오.

$$H(X|Y) = H(X, Y) - H(Y) = 1.782 - 0.996 = 0.786 \text{ bits}$$

4) 폐암 발병 여부  $X$ 와 흡연 여부  $Y$ 의 Mutual Information  $I(X ; Y)$ 을 계산하시오.

$$I(X; Y) = H(X) + H(Y) - H(X, Y) = 0.971 + 0.996 - 1.782 = 0.185 \text{ bits}$$

5) 4)의 결과로 나온  $I(X ; Y)$ 의 의미를 통계적 관점에서 간략하게 해석하고,

$I(X ; Y)$ 값이 0 일 경우와,  $H(X)$ 와 같을 경우 각각 어떤 의미를 갖는지 설명하시오.

💡 엔트로피 계산 시  $\log$ 의 밑은 2로 계산하면 됩니다.

💡 단위는 비트(bits)를 이용하여,  $\log$  계산 값은 근사치로만 이용하시면 됩니다.

$$\textcircled{1} I(X; Y) = 0.185 \text{라는 것은 } X \text{를 통해 } Y \text{에 대해 얻어지는 정보량이 } 0.185 \text{라는 것이다.}$$

→ 즉  $Y$ 의 정보량이 줄어들면, mutual information 값이 감소하게 된다.

$$\textcircled{2} I(X; Y) = 0 \text{인 경우는 } X \text{와 } Y \text{의 상관성이 } 0 \text{인 경우이다.}$$

$$\textcircled{3} I(X; Y) = H(X) \text{인 경우는, } Y \text{는 } X \text{에 대한 정보를 모두 갖고 있어, } X \text{를 통해 } Y \text{의 확률이 가능하게 하는 경우이다.}$$

## 문제 2 SVD and Data Compression

선형대수학은 머신러닝과 딥러닝의 원리를 수학적으로 분석하는 과정에서 사용되는 핵심적인 내용 중 하나로, 그 중에서도 가장 중요한 개념은 바로 SVD (Singular Value Decomposition, 특이값 분해)입니다. SVD를 이해하기 위해 우선 고유값과 고유벡터를 활용한 대각화 (Diagonalization)에 대해 알아보겠습니다.

2-1 🌟 : 대각화 (Diagonalization)의 정의와 계산 과정은 다음과 같습니다.

💡 정의: 임의의 정방행렬  $A$ 를 고유값과 고유벡터를 통해 대각행렬의 형태로 선형 변환하는 과정이며, 이를 수식으로 표현하면  $D = P^{-1}AP$ 를 만족하는 대각행렬  $D$ 를 찾는 것입니다. 만약  $A$ 가  $n$  개의 독립인 고유벡터를 가지고 있다면 (= 가역이라면)  $A$ 는 대각화 가능하며, 이때 대각행렬의 원소는  $A$ 의 고유값으로 구성됩니다.

💡 과정:

- 1)  $A$ 에 대한 고유값과 이에 대응하는 고유벡터를 찾은 후 각각  $p_1, p_2, \dots, p_n$ 으로 놓습니다.
- 2) 고유벡터로 구성된 행렬  $P = [p_1, p_2, \dots, p_n]$ 을 만들고  $D = P^{-1}AP$ 을 구합니다.

다음 정방행렬을 대각화했을 때 나오는 대각행렬  $D$ 와 고유벡터 행렬  $P$ 를 각각 구하세요.

$$\begin{aligned}
 & \det(A - \lambda I) = 0 \\
 & A - \lambda I = \begin{bmatrix} 2-\lambda & 0 & 0 \\ 1 & 2-\lambda & 1 \\ -1 & 0 & 1-\lambda \end{bmatrix} \quad (\text{위치 } \lambda = 1 \text{ 일 때 }) \\
 & (A - \lambda I)v = 0 \quad (A - \lambda I)v = 0 \\
 & \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ -1 & 0 & 0 \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = 0 \\
 & \begin{array}{l} a=0 \\ b+c=0 \\ b=-c \end{array} \quad \begin{array}{l} a=0 \\ a+b+c=0 \\ -\lambda=0 \end{array} \quad \begin{array}{l} b=0 \\ b+c=0 \\ b=-c \end{array} \quad \begin{array}{l} c=0 \\ b+c=0 \\ b=-c \end{array} \\
 & \det(A - \lambda I) = (2-\lambda)(1-\lambda)(1-\lambda) = 0 \quad \lambda = 2, 1 \\
 & \therefore \lambda = 2, 1 \\
 & \text{위치 } \lambda = 2 \text{ 일 때 } \\
 & (A - 2I)v = 0 \quad \left( \begin{bmatrix} 0 & 0 & 0 \\ 1 & 0 & 1 \\ -1 & 0 & -1 \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = 0 \right) \\
 & \begin{bmatrix} 0 & 0 & 0 \\ 1 & 0 & 1 \\ -1 & 0 & -1 \end{bmatrix} \begin{bmatrix} -c \\ b \\ c \end{bmatrix} = 0 \quad \begin{bmatrix} 0 & 0 & -1 \\ -1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} -c \\ b \\ c \end{bmatrix} = 0 \\
 & \begin{bmatrix} v \\ v \\ v \end{bmatrix} = \begin{bmatrix} -c \\ b \\ c \end{bmatrix} \quad \begin{bmatrix} 0 & 0 & -1 \\ -1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} = D \\
 & \quad P = [P_1, P_2, P_3] \quad P^{-1} = \begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 1 \\ -1 & 0 & 0 \end{bmatrix} \quad AP = \begin{bmatrix} 0 & 0 & -2 \\ -1 & 2 & 0 \\ 0 & 0 & 2 \end{bmatrix} \quad P^{-1}AP = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{bmatrix} = D
 \end{aligned}$$

2-2 🌟 : (Optional) 대칭행렬이 직교대각화(Orthogonal Diagonalization)가 가능하다는 것은 필요충분조건이며, 이는 대칭행렬의 중요한 성질 중 하나입니다. 이를 증명하시오.

💡 직교대각화의 정의는 다음과 같습니다.

'정사각행렬  $A$ 가 주어져있을 때,  $P^{-1}AP = P^TAP$ 가 대각행렬이 되게 만드는  $P$ 가 존재한다면,  $A$ 를 직교대각화 가능하다고 하고,  $P$ 가  $A$ 를 직교대각화 한다고 한다.'

💡 직교대각화 -> 대칭행렬을 증명하는 과정은 위의 정의를 이용하면 됩니다.

💡 대칭행렬 -> 직교대각화를 증명하기 위해서는 아래의 내용들을 증명하면 됩니다.

- 1) 모든 성분이 실수인 대칭행렬은 실수 고유값만을 갖는다. (해당 내용은 그냥 이용해도 무방)
- 2)  $n \times n$  행렬  $A$ 가 직교대각화 가능하다는 말은  $A$ 가 서로 정규직교하는  $n$  개의 고유벡터들을 가진다는 말과 동치이다. -> 즉, 서로 다른 고유값에 대응하는 고유벡터들은 항상 서로 직교한다.
- 3) 각 고유값에 대해 대수적 중복도와 기하적 중복도가 항상 일치한다.

값이 0인 행과 열은 제거합니다.

1) 통.

2-3 🔥: 특이값 분해 (SVD, Singular Value Decomposition)은 대각화와 달리 모든 크기의 행렬에 대해 적용이 가능하며, 그 계산 과정은 다음과 같습니다.

- 💡 1) 항상 대칭 행렬을 이루는 두 행렬  $B^T B, BB^T$ 를 계산하고, 이들의 고유값을 계산해 특이값  $\sigma$ 와 고유벡터를 통해 직교대각화하여  $B^T B = V D V^T, BB^T = U D U^T$ 를 구합니다.
- 2) 0이 아닌 특이값들을 내림차순으로 나열하여  $\Sigma$ 를 구성하고, 이들을 모두 활용해  $A = U \Sigma V^T$ 를 구합니다.

계산 방법에 대한 구체적인 과정은 다음의 영상 자료 ([링크](#))를 반드시 참고하여 문제를 풀어주세요.

다음 행렬에 특이값 분해를 적용하였을 때 나오는 행렬  $U, \Sigma, V^T$ 를 각각 구하세요.

$$B = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$BB^T = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$$

① U 값 :  $BB^T$ 의 단위 고유벡터

$$\det(BB^T - \lambda I) = 0$$

ii)  $\lambda = 1$  일 때,

$$\begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} a \\ b \end{bmatrix}$$

$$\begin{bmatrix} 2a \\ b \end{bmatrix} = \begin{bmatrix} a \\ b \end{bmatrix}$$

$$v = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

$$B - \lambda I = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} - \lambda \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 2-\lambda & 0 \\ 0 & 1-\lambda \end{bmatrix}$$

$$\det(B - \lambda I) = (2-\lambda)(1-\lambda) = 0 \quad \therefore \lambda = 2, 1$$

iii)  $\lambda = 2$  일 때

$$\begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = 2 \begin{bmatrix} a \\ b \end{bmatrix} \quad \text{방정식 풀기}$$

$$\begin{bmatrix} 2a \\ b \end{bmatrix} = \begin{bmatrix} 2a \\ 2b \end{bmatrix}$$

$$v = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

②  $\Sigma$  값 :  $B B^T$ 의 고유값

$$\therefore \lambda = 2, 1$$

③ V 값 :  $B^T B$ 의 단위 고유ベクトル

$$B^T B = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$\det(B^T B - \lambda I)$$

$$\begin{bmatrix} 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} - \lambda \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1-\lambda & 1 & 0 \\ 1 & 1-\lambda & 0 \\ 0 & 0 & 1-\lambda \end{bmatrix}$$

$$(1-\lambda)((1-\lambda)^2 - 1) = 0$$

$$(1-\lambda)(1-2\lambda+\lambda^2 - 1) = 0$$

$$(1-\lambda)(\lambda^2 - 2\lambda) = 0$$

$$\lambda(1-\lambda)(\lambda-2) = 0$$

$$\lambda = 0, 1, 2$$

i)  $\lambda = 0$  일 때

$$B^T B V = 0$$

$$\begin{bmatrix} 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = 0$$

$$a+b=0$$

$$a+b=0$$

$$c=0$$

$$V = \begin{bmatrix} a \\ -a \\ 0 \end{bmatrix}$$

$a=1$  일 때

$$V = \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}$$

$$V = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$C=1010\overline{0}, V=\begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

$$\therefore \Sigma = 0, 1, \sqrt{2}$$

ii)  $\lambda = 1$  일 때

$$(B^T B - I) V = 0$$

$$\begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = 0$$

$$b=0$$

$$a=0$$

$$V = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

iii)  $\lambda = 2$  일 때

$$(B^T B - 2I) V = 0$$

$$\begin{bmatrix} -1 & 1 & 0 \\ 1 & -1 & 0 \\ 0 & 0 & -1 \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = 0$$

$$-a+b=0$$

$$a-b=0$$

$$-c=0$$

$$a=b, c=0$$

$$V = \begin{bmatrix} a \\ a \\ 0 \end{bmatrix}$$

$$a=1010\overline{0}, V=\begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}$$

### 문제 3 Optimization Theory

최적화는 다양한 분야에서 많이 쓰이는 개념이지만, 특히 머신러닝에서는 최적의 정답을 찾기 위해 필수적으로 사용되는 개념입니다. 정규세션으로 이를 간단하게 배워보았고, 직접 수식으로 문제를 풀어보며 해당 개념을 익히고자 합니다.

3-1 🔥: 정규세션에서 살펴본 것과 같이, Logistic Regression의 목적함수는 아래와 같습니다.

$$\min_w \sum_{i=1}^m \{-y^{(i)} \log(\hat{y}^{(i)}) - (1-y^{(i)}) \log(1-\hat{y}^{(i)})\}$$

최적해를 구하기 위해서는 먼저 내부의 목적 함수가 convex function인지 여부를 판단해야 합니다. 내부 목적 함수  $-y^{(i)} \log(\hat{y}^{(i)}) - (1-y^{(i)}) \log(1-\hat{y}^{(i)})$  가 convex function임을 보이세요.

💡  $y^{(i)}$  을 Logistic Function 식을 활용하면  $\hat{y}^{(i)} = \frac{1}{1+e^{-w^T x^{(i)}}}$  과 같이 표현할 수 있습니다.

💡 목적 함수를 두 부분으로 나누어서 각각 Convex 하다는 것을 증명하면 됩니다.

💡 convexity를 증명하기 위해서는  $w$ 에 대해 2 번 미분하여, 0보다 크다는 것을 보이면 됩니다.

Convexity 증명  
정밀한 증명에 대해서는 향후 학습

$$L(w) = -y \log(\hat{y}) - (1-y) \log(1-\hat{y})$$

$$\sigma(z) = \frac{1}{1+e^{-z}} = \text{sigmoid 함수}$$

$$\hat{y} = \sigma(w^T x)$$

$$\frac{\partial L(w)}{\partial \hat{y}} = -(y \times \frac{1}{\hat{y}} + (1-y) \times \frac{-1}{1-\hat{y}})$$

$$\frac{\partial^2 L(w)}{\partial \hat{y}^2} = \frac{y}{\hat{y}^2} + \frac{1-y}{(1-\hat{y})^2}$$

$\hat{y}$ 는 sigmoid 함수의 결과 값으로 0과 1 사이의 값을 갖는다.  
 $\therefore \hat{y}^2 \& (1-\hat{y})^2$ 는 양수의 제곱이므로, 늘 양수임.  
 $y$ 는 0이거나 1이거나 양수임.  
 $\therefore \frac{\partial^2 L(w)}{\partial \hat{y}^2} \geq 0$   
 $\therefore \text{Convex } \frac{1}{2} \hat{y}.$

3-2 🔥: Minimization에 대한 Gradient Descent Algorithm은 아래와 같습니다.

$$\min_{x \in X} f(x)$$

$$x_{t+1} = x_t - \underbrace{\gamma \nabla_x f(x_t)}_{\text{learning rate}}$$

$\nabla_x f(x_t)$ :  $f(x_t)$ 에 대해서  $x_t$  지점에서 미분한 값

다음과 같은 Loss function과 시작점에서  $t=2$ 일 때 나오는 값, 즉  $x_2$ 의 값을 구하세요.

$$f(x) = x^4 - 2x^3 - 3x^2 + x$$

$$\nabla_x f(x_0) = f'(x) = 4x^3 - 6x^2 - 6x + 1$$

$$t=0, x_0 = 1$$

$$x_1 = x_0 - \gamma \nabla_x f(x_0)$$

$$\nabla_x f(x_0) = 4-6-6+1 = -7$$

$$x_1 = 1 - 0.2 \times (-7)$$

$$= 1 + 1.4 = 2.4$$

$$x_2 = x_1 - \gamma \nabla_x f(x_1)$$

$$\begin{aligned} & t=1, x_1 = 2.4 \\ & x_2 = 2.4 - 0.2 \times (4 \times 2.4^3 - 6 \times 2.4^2 - 6 \times 2.4 + 1) \\ & = 2.4 - 0.2 \times 7.376 = 0.9328 \end{aligned}$$

$$\therefore x_2 = 0.9328$$

### 3-3 🌟: 라그랑주 승수법은 아래와 같습니다.

💡 라그랑주 승수(Lagrange Multiplier)는 제약 조건이 있는 최적화 문제를 제약 조건이 없는 문제로 변환하여 최적해를 찾기 위한 보조 변수를 말합니다. 제약 조건이 없을 때는 단순히  $\nabla f(x)=0$  으로 최적점을 찾을 수 있지만, 제약조건  $g(x)$ 가 있을 때는 최적해는 제약을 만족하면서  $f(x)$ 를 최소화하는 지점이 되어야 합니다. 이를 위해 제약 조건과 목적함수를 결합한 새로운 함수 (lagrangian)을 만들고, 그 stationary point 를 찾아서 목적함수 최적화와 제약 만족을 동시에 달성할 수 있습니다.

제약 조건이 있는 최적화 문제:

$$\min_x f(x) \quad \text{subject to } g(x) = 0$$

→ 이를 다음과 같은 Lagrangian 함수로 바꿉니다:

$$L(x, \lambda) = f(x) + \lambda \cdot g(x)$$

25-2 Mathematics for ML #2 세션 자료 中

사진의  $\lambda$ 가 라그랑주 승수입니다. 제약조건을 penalty 처럼 반영하여 이를 만족시키는 해를 찾아낼 수 있습니다.

다음 조건을 만족하는  $f(x, y)$ 의 최솟값을 라그랑주 승수법을 이용해 구하세요.

$$\min f(x, y) = x^2 + y^2 \quad \text{s.t. } x + y \geq 2$$

2-x-y \leq 0



1) 주어진 목적 함수와 제약 조건을 이용하여 lagrangian  $L(x, y, \lambda)$ 을 설정하세요.

$$L(x, y, \lambda) = x^2 + y^2 + \lambda \cdot (2-x-y)$$

2)  $L(x, y, \lambda)$ 을 각 변수에 대해 편미분하고, 그 값이 0 이 되는 stationary point 조건을 제시하세요.

$$\frac{\partial L}{\partial x} = 2x - \lambda = 0 \quad \frac{\partial L}{\partial y} = 2y - \lambda = 0 \quad \frac{\partial L}{\partial \lambda} = 2-x-y = 0$$

3) 위에서 얻은 조건들을 만족하는  $x, y, \lambda$  의 값을 계산하세요.

$$\begin{aligned} x+y &= 1 \\ \lambda &= 2 \end{aligned}$$

4) 구한  $f(x, y)$ 값을 목적함수  $f(x, y)$ 에 대입하여 최솟값을 계산하세요.

$$f(1, 1) = 2$$

---

#### Reference

- 24-1 기초과제 2 (10 기 신재우)
- 24-2 기초과제 (11 기 김현진, 김정우)
- 25-1 Mathematics for ML 과제 (12 기 김민규)
- Information Theory for Data Science, Prof. Son, Fall 2024, Yonsei Univ.

#### Data Science Lab

담당자: 13 기 조지성  
[xiwang01@yonsei.ac.kr](mailto:xiwang01@yonsei.ac.kr)