

## 25-2 DSL 정규 세션

## Mathematics for ML 과제



- 본 과제는 학회 정규 세션 「Mathematics for Machine Learning」의 내용을 다루며, 개념의 적용과 실제 활용 사례에 대한 이해를 돋기 위해 기획되었습니다. 해당 과제는 평가를 위한 것이 아니므로, 주어진 힌트(💡)를 적극 활용하시고 학회원 간 토론 및 Slack 질의응답을 적극 활용하여 해결해주십시오. **단, 답안 표절이나 LLM 의 남용은 금지합니다.**
- 각 문제에서 요구하는 방법에 맞게 해결하며, 서술형 문제들은 따로 작성하시어 .pdf 파일로 답안을 작성하여 제출해 주십시오.
- 7/30 (수) 23 시 59 분까지 Github 에 .pdf 파일을 제출해 주십시오. Github 에 제출하는 방법을 모른다면 학술부 (강승우, 조지성, 한연주)로 문의 주시기 바랍니다.

## 문제 1 Entropy and Mutual Information

다음은 어느 드라마의 한 장면 중 일부입니다.

“…지는 분은 물론 벌칙이 있습니다. 아마 영화에서 보신 적이 있으실 겁니다, 러시안룰렛이라고. 이 권총에 총알 하나를 넣고 닫습니다. 그리고 지는 분 쪽으로 방아쇠를 당길 겁니다. 죽을 확률이 1/6, 살 확률은 5/6. 생각보다 나쁘지 않죠? (중략) …조금 지루한 감이 없지 않아 있네요. 그럼 이제 확률을 뒤집어 볼까요? 권총에 총알 다섯 개를 넣고 닫습니다. 확률은 1/6, 죽을 확률은 5/6. 자, 다시 시작하겠습니다.”

그러나 사실은 두 상황 모두 엔트로피의 측면에서의 지루함, 즉 불확실성은 같습니다! 총알이 발사될 확률이 각각 1/6, 5/6 인 베르누이 분포를 따르기 때문에, 엔트로피의 정의를 따라 계산하면 같은 값이 나오는 것이죠.

이 문제에서는 이처럼 주어진 사건들이 이산적인 경우 엔트로피의 성질을 알아보고, 직접 계산해보며 엔트로피와 Mutual Information 이 가진 의미를 알아보고자 합니다.

1-1 🎉 : 주사위를 던졌을 때 나오는 눈의 사건을 X 라 하고, 각 눈이 나올 확률을  $p_i$  ( $0 \leq p_i \leq 1$ ,  $\sum_{i=1}^6 p_i = 1$ ) 이라 할 때, 아래의 조건에서 주사위의 엔트로피  $H(X)$ 를 각각 구하세요.  $H(X)$ 는 언제 최대가 되는지 간단한 이유 (내지는 직관)와 함께 서술하세요.

💡 엔트로피의 정의:  $H(X) = \sum_{x \in X} p(x) \log_2 \{1/p(x)\} = \sum_{x \in X} -p(x) \log_2 \{p(x)\}$

1) 공정한 주사위 (모든  $p_i = 1/6$ )

2) 모든 눈이 6 인 주사위

3) 짹수 눈이 나올 확률이 홀수 눈이 나올 확률의 2 배인 주사위((nullable 각각 및 홀수 각각의 확률은 동일)

4) 1 이 나올 확률이 0.5, 나머지 눈이 나올 확률이 각각 0.1 인 주사위

1-2 🔥 : 임의의 이산화률변수  $X$ 에 대하여  $X$ 가 가질 수 있는 값의 집합을  $\mathcal{X}$ 라 합시다. 예를 들어, 동전을 1회 던졌을 때의  $\mathcal{X} = \{\text{Head}, \text{Tail}\}$ 로  $|\mathcal{X}| = 2$ 입니다. 이때 엔트로피  $H(X)$ 가 가질 수 있는 값의 범위가  $0 \leq H(X) \leq \log_2 |\mathcal{X}|$ 임을 증명하세요.

- 💡 좌측 부등식의 경우, 확률 값의 성질을 활용해 증명 가능합니다.
- 💡 우측 부등식의 경우, 아래의 Jensen's Inequality 를 활용해 증명 가능합니다.
  - Jensen's Inequality:  $\mathbb{E}[f(X)] \geq f(\mathbb{E}[X])$  for a convex  $f$ , and  $\mathbb{E}[f(X)] \leq f(\mathbb{E}[X])$  for a concave  $f$
  - (Bonus Question: Jensen's Inequality 는 어떻게 증명할까요? Hint: 수학적 귀납법으로 n=2 부터...!)

1-3 🔥 : 어떤 지역 주민들의 흡연 여부 ( $X$ )와 폐암 발병 여부 ( $X$ )에 대한 설문 조사를 실시하여 다음과 같은 결합 확률 분포를 얻었다고 가정합니다. 여기서  $X = 1$ 은 폐암 발병,  $X = 0$ 은 폐암 미발병을 의미하며,  $Y = 1$ 은 흡연,  $Y = 0$ 은 비흡연을 의미합니다. 아래 질문에 답해주세요.

$P(X, Y)$	$Y = 0$ (비흡연)	$Y = 1$ (흡연)
$X = 0$ (폐암 미발병)	0.45	0.15
$X = 1$ (폐암 발병)	0.1	0.3

- 1) 폐암 발병 여부  $X$  와 흡연 여부  $Y$  의 엔트로피  $H(X)$ ,  $H(Y)$ 를 계산하시오.
- 2)  $X$  와  $Y$  의 결합 엔트로피  $H(X, Y)$ 를 계산하시오.
- 3) 흡연 여부  $Y$  에 대한 정보가 주어졌을 때, 폐암 발병 여부  $X$  의 조건부 엔트로피  $H(X | Y)$ 를 계산하시오.
- 4) 폐암 발병 여부  $X$  와 흡연 여부  $Y$  의 Mutual Information  $I(X ; Y)$ 를 계산하시오.
- 5) 4)의 결과로 나온  $I(X ; Y)$ 의 의미를 통계적 관점에서 간략하게 해석하고,  
 $I(X ; Y)$ 값이 0 일 경우와,  $H(X)$ 와 같을 경우 각각 어떤 의미를 갖는지 설명하시오.

- 💡 엔트로피 계산 시  $\log$  의 밑은 2로 계산하면 됩니다.
- 💡 단위는 비트(bits)를 이용하며,  $\log$  계산 값은 근사치로만 이용하시면 됩니다.

## 문제 2 SVD and Data Compression

선형대수학은 머신러닝과 딥러닝의 원리를 수학적으로 분석하는 과정에서 사용되는 핵심적인 내용 중 하나로, 그 중에서도 가장 중요한 개념은 바로 SVD (Singular Value Decomposition, 특이값 분해)입니다. SVD를 이해하기 위해 우선 고유값과 고유벡터를 활용한 대각화 (Diagonalization)에 대해 알아보겠습니다.

2-1 : 대각화 (Diagonalization)의 정의와 계산 과정은 다음과 같습니다.

💡 정의: 임의의 정방행렬  $A$ 를 고유값과 고유벡터를 통해 대각행렬의 형태로 선형 변환하는 과정이며, 이를 수식으로 표현하면  $D = P^{-1}AP$ 를 만족하는 대각행렬  $D$ 를 찾는 것입니다. 만약  $A$ 가  $n$  개의 독립인 고유벡터를 가지고 있다면 (= 가역이라면)  $A$ 는 대각화 가능하며, 이때 대각행렬의 원소는  $A$ 의 고유값으로 구성됩니다.

💡 과정:

- 1)  $A$ 에 대한 고유값과 이에 대응하는 고유벡터를 찾은 후 각각  $p_1, p_2, \dots, p_n$ 으로 놓습니다.
- 2) 고유벡터로 구성된 행렬  $P = [p_1, p_2, \dots, p_n]$ 을 만들고  $D = P^{-1}AP$ 을 구합니다.

다음 정방행렬을 대각화했을 때 나오는 대각행렬  $D$ 와 고유벡터 행렬  $P$ 를 각각 구하세요.

$$A = \begin{bmatrix} 2 & 0 & 0 \\ 1 & 2 & 1 \\ -1 & 0 & 1 \end{bmatrix}$$

2-2 : (Optional) 대칭행렬이 직교대각화(Orthogonal Diagonalization)가 가능하다는 것은 필요충분조건이며, 이는 대칭행렬의 중요한 성질 중 하나입니다. 이를 증명하시오.

💡 직교대각화의 정의는 다음과 같습니다.

'정사각행렬  $A$ 가 주어져있을 때,  $P^{-1}AP = P^TAP$ 가 대각행렬이 되게 만드는  $P$ 가 존재한다면,  $A$ 를 직교대각화 가능하다고 하고,  $P$ 가  $A$ 를 직교대각화 한다고 한다.'

💡 직교대각화 -> 대칭행렬을 증명하는 과정은 위의 정의를 이용하면 됩니다.

💡 대칭행렬 -> 직교대각화를 증명하기 위해서는 아래의 내용들을 증명하면 됩니다.

- 1) 모든 성분이 실수인 대칭행렬은 실수 고유값만을 갖는다. (해당 내용은 그냥 이용해도 무방)
- 2)  $n \times n$  행렬  $A$ 가 직교대각화 가능하다는 말은  $A$ 가 서로 정규직교하는  $n$  개의 고유벡터들을 가진다는 말과 동치이다. -> 즉, 서로 다른 고유값에 대응하는 고유벡터들은 항상 서로 직교한다.
- 3) 각 고유값에 대해 대수적 중복도와 기하적 중복도가 항상 일치한다.

2-3 🔥 : 특이값 분해 (SVD, Singular Value Decomposition)은 대각화와 달리 모든 크기의 행렬에 대해 적용이 가능하며, 그 계산 과정은 다음과 같습니다.

- 💡 1) 항상 대칭 행렬을 이루는 두 행렬  $B^T B, BB^T$ 를 계산하고, 이들의 고유값을 계산해 특이값  $\sigma$ 와 고유벡터를 통해 직교대각화하여  $B^T B = VDV^T, BB^T = UDU^T$ 를 구합니다.
- 2) 0 이 아닌 특이값들을 내림차순으로 나열하여  $\Sigma$ 를 구성하고, 이들을 모두 활용해  $A = U\Sigma V^T$ 를 구합니다.

계산 방법에 대한 구체적인 과정은 다음의 영상 자료 ([링크](#))를 반드시 참고하여 문제를 풀어주세요.

다음 행렬에 특이값 분해를 적용하였을 때 나오는 행렬  $U, \Sigma, V^T$ 를 각각 구하세요.

$$B = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

### 문제 3 Optimization Theory

최적화는 다양한 분야에서 많이 쓰이는 개념이지만, 특히 머신러닝에서는 최적의 정답을 찾기 위해 필수적으로 사용되는 개념입니다. 정규세션으로 이를 간단하게 배워보았고, 직접 수식으로 문제를 풀어보며 해당 개념을 익하고자 합니다.

3-1 🔥 : 정규세션에서 살펴본 것과 같이, Logistic Regression 의 목적함수는 아래와 같습니다.

$$\min_w \sum_{i=1}^m \{-y^{(i)} \log(\hat{y}^{(i)}) - (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})\}$$

최적해를 구하기 위해서는 먼저 내부의 목적 함수가 convex function 인지 여부를 판단해야 합니다. 내부 목적 함수  $-y^{(i)} \log(\hat{y}^{(i)}) - (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})$  가 convex function임을 보이세요.

💡  $y^{(i)}$  을 Logistic Function 식을 활용하면  $\hat{y}^{(i)} = \frac{1}{1+e^{-w^T x^{(i)}}}$  과 같이 표현할 수 있습니다.

💡 목적 함수를 두 부분으로 나누어서 각각 Convex 하다는 것을 증명하면 됩니다.

💡 convexity를 증명하기 위해서는 w에 대해 2 번 미분하여, 0 보다 크다는 것을 보이면 됩니다.

3-2 🔥 : Minimization에 대한 Gradient Descent Algorithm은 아래와 같습니다.

$$\min_{x \in X} f(x)$$

$$x_{t+1} = x_t - \gamma \nabla_x f(x_t)$$

$\nabla_x f(x_t)$ :  $f(x_t)$ 에 대해서  $x_t$  지점에서 미분한 값

다음과 같은 Loss function과 시작점에서 t = 2 일 때 나오는 값, 즉  $x_2$ 의 값을 구하세요.

$$f(x) = x^4 - 2x^3 - 3x^2 + x$$

$$x_0 = 1, \quad \gamma = 0.2$$

### 3-3 🔥: 라그랑주 승수법은 아래와 같습니다.

💡 라그랑주 승수(Lagrange Multiplier)는 제약 조건이 있는 최적화 문제를 제약 조건이 없는 문제로 변환하여 최적해를 찾기 위한 보조 변수를 말합니다. 제약 조건이 없을 때는 단순히  $\nabla f(x)=0$  으로 최적점을 찾을 수 있지만, 제약조건  $g(x)$ 가 있을 때는 최적해는 제약을 만족하면서  $f(x)$ 를 최소화하는 지점이 되어야 합니다. 이를 위해 제약 조건과 목적함수를 결합한 새로운 함수 (lagrangian)을 만들고, 그 stationary point 를 찾아서 목적함수 최적화와 제약 만족을 동시에 달성할 수 있습니다.

제약 조건이 있는 최적화 문제:

$$\min_x f(x) \quad \text{subject to } g(x) = 0$$

→ 이를 다음과 같은 Lagrangian 함수로 바꿉니다:

$$L(x, \lambda) = f(x) + \lambda \cdot g(x)$$

25-2 Mathematics for ML #2 세션 자료 中

사진의  $\lambda$ 가 라그랑주 승수입니다. 제약조건을 penalty 처럼 반영하여 이를 만족시키는 해를 찾아낼 수 있습니다.

다음 조건을 만족하는  $f(x, y)$ 의 최솟값을 라그랑주 승수법을 이용해 구하세요.

$$\min f(x, y) = x^2 + y^2 \quad s.t. \quad x + y \geq 2$$

1) 주어진 목적 함수와 제약 조건을 이용하여 lagrangian  $L(x, y, \lambda)$ 을 설정하세요.

2)  $L(x, y, \lambda)$ 을 각 변수에 대해 편미분하고, 그 값이 0 이 되는 stationary point 조건을 제시하세요.

3) 위에서 얻은 조건들을 만족하는  $x, y, \lambda$  의 값을 계산하세요.

4) 구한  $f(x, y)$ 값을 목적함수  $f(x, y)$ 에 대입하여 최솟값을 계산하세요.

---

#### Reference

- 24-1 기초과제 2 (10 기 신재우)
- 24-2 기초과제 (11 기 김현진, 김정우)
- 25-1 Mathematics for ML 과제 (12 기 김민규)
- Information Theory for Data Science, Prof. Son, Fall 2024, Yonsei Univ.

#### Data Science Lab

담당자: 13 기 조지성  
[xiwang01@yonsei.ac.kr](mailto:xiwang01@yonsei.ac.kr)

$$1-2 \quad 0 \leq H(X) \leq \log_2 |X|$$

(1) 정수부등식

$$\begin{aligned} 0 &\leq p(s) \leq 1, \sum p(s) = 1 \\ \Rightarrow \log_2(p(s)) &\leq 0 \quad \therefore p(s) \log_2(p(s)) \leq 0. \end{aligned}$$

$$H(X) = -\sum p(s) \log_2 p(s) \geq 0$$

(2) 우증부등식

$X$ 가 균일 분포 일 때  $H(X)$ 가 최대가 된다.

$$\text{이 때 } p(x) = \frac{1}{|X|}$$

$$\begin{aligned} H(X) &= -\sum_{x \in X} \frac{1}{|X|} \log_2 \frac{1}{|X|} = -|X| \cdot \frac{1}{|X|} \log_2 \frac{1}{|X|} \\ &= \log_2 |X| \end{aligned}$$

$X$  균일 분포가 아닐 때

$\log_2(s)$ 는 凹 (concave)

$$\therefore E[f(X)] \leq f(E[X])$$

$$-\sum_{x \in X} p(x) \log_2 p(x) \leq -\log_2 \left( \underbrace{\sum_{x \in X} p(x) \cdot p(x)}_{H(X)} \right)$$

$$\underbrace{-\sum_{x \in X} p(x) \log_2 p(x)}_{H(X)} \leq -\log_2 \left( \underbrace{\sum_{x \in X} p(x) \cdot p(x)}_{\log_2 |X|} \right)$$

1-1

$$1) P_i = \frac{1}{6}$$

$$H(X) = \sum_{i=1}^6 -\frac{1}{6} \log_2 \frac{1}{6} = 6 \cdot \left( -\frac{1}{6} \log_2 \frac{1}{6} \right) = \log_2 6 \approx 2.58$$

2)

$$P_C = 1, P_{i \neq 6} = 0$$

$$H(X) = -(1 \cdot \log_2 1 + \sum_{i \neq 6} 0 \cdot \log_2 0) = 0 \text{ bits}$$

3)

작수면 확률 각각  $\frac{2}{9}$ , 흘수면 확률 각각  $\frac{1}{9}$

$$\begin{aligned} H(X) &= - \left[ 3 \left( \frac{1}{9} \log_2 \frac{1}{9} \right) + 3 \left( \frac{2}{9} \log_2 \frac{2}{9} \right) \right] \\ &\approx - \left( \frac{1}{3} \log_2 \frac{1}{9} + \frac{2}{3} \log_2 2 - \frac{2}{3} \log_2 9 \right) = - \left( \frac{2}{3} - \log_2 9 \right) \approx 2.50 \end{aligned}$$

$$4) P(X=1) = 0.5 \quad \text{나머지 } 0.1$$

$$H(X) = - [0.5 \log_2 0.5 + 5 \times 0.1 \log_2 0.1] \approx 2.16$$

1)의 경우  $H(X)$ 가 조건

2-1

$$\det(A - \lambda I_3) = \begin{vmatrix} 2-\lambda & 0 & 0 \\ 1 & 2-\lambda & 1 \\ -1 & 0 & 1-\lambda \end{vmatrix} = (2-\lambda)(2-\lambda)(1-\lambda) = 0$$

$$\therefore \lambda_1 = 2, \lambda_2 = 1$$

$$\text{i) } \lambda_1 = 2$$

(A-2I)X = 0     $\begin{bmatrix} 0 & 0 & 0 \\ 1 & 0 & 1 \\ -1 & 0 & -1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = 0$      $x_3 = -x_1$      $x_2 = 0$      $x_1 = t$      $X = s \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} + t \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$

ii)  $\lambda_2 = 1$ 

$$(A-I)X = 0 \quad \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ -1 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = 0 \quad x_1 = 0, x_2 = -x_3 \quad X = \begin{bmatrix} 0 \\ -1 \\ 1 \end{bmatrix}$$

$$\therefore P = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & -1 \\ 0 & -1 & 1 \end{bmatrix} \quad D = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

1-3.

1)  $H(X), H(Y)$  계산

$$P(X=0) = 0.45 + 0.15 = 0.6$$

$$P(X=1) = 0.4$$

$$P(Y=0) = 0.55$$

$$P(Y=1) = 0.45$$

$$H(X) = -[0.6 \log_2 0.6 + 0.4 \log_2 0.4] = 0.971$$

$$H(Y) = -[0.55 \log_2 0.55 + 0.45 \log_2 0.45] \approx 0.993$$

2)  $H(X,Y)$  계산

$$H(X,Y) = -\sum_{x,y} P(x,y) \log_2 P(x,y)$$

$$= -[0.45 \log_2 0.45 + 0.15 \log_2 0.15 + 0.1 \log_2 0.1 + 0.3 \log_2 0.3]$$

$$\approx 1.18$$

$$3) H(X|Y) = H(X) - H(Y) = 1.18 - 0.993 = 0.187$$

$$4) I(X;Y) = H(X) + H(Y) - H(X,Y) = 0.971 + 0.993 - 1.18 = 0.184$$

5)  $I(X;Y)$ 은 흡연 여부를 알면 폐암 여부에 대해 평균적으로 0.184 bit 만큼 불확실성이 줄어든다는 의미.

$I(X;Y) = 0$ 이면  $X$ 와  $Y$ 가 통계적으로 독립이라는 뜻.

$H(X)=0$ 이면  $X$ 가 항상 하나의 값을 가지므로 (불확실성 0), 정보량이 0인 결정적 변수이다.

2-3

$$B = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad B^T = \begin{bmatrix} 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$BB^T = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \quad B^T B = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \lambda_1=2, \lambda_2=1, \lambda_3=0 \Rightarrow \sigma_1=\sqrt{2}, \sigma_2=1$$

$$w_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, w_2 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}, w_3 = \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}$$

$$v_1 = \begin{bmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \\ 0 \end{bmatrix}, v_2 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}, v_3 = \begin{bmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \\ 0 \end{bmatrix}$$

$$V = \begin{bmatrix} 1/\sqrt{2} & 0 & -1/\sqrt{2} \\ 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \end{bmatrix}, \Sigma = \begin{bmatrix} \sqrt{2} & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$

$$u_1 = \frac{1}{\sigma_1} B v_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \\ 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad u_2 = \frac{1}{\sigma_2} B v_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

$$U = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad B = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \sqrt{2} & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} & 0 \\ 0 & 0 & 1 \\ -1/\sqrt{2} & 1/\sqrt{2} & 0 \end{bmatrix}$$

$$\begin{matrix} 1 & & \\ & 1 & \\ U & & \end{matrix} \quad \begin{matrix} & & \\ & & 1 \\ \Sigma & & \end{matrix} \quad \begin{matrix} & & \\ & & \sqrt{\tau} \end{matrix}$$

3-2.

$$\text{min } f(x) = x^4 - 2x^3 - 3x^2 + x \quad f'(x) = 4x^3 - 6x^2 - 6x + 1$$

$$x_0 = 1.04141 \quad f(1) = -7. \quad x_1 = x_0 - \gamma f'(x_0) = 1 - 0.2 \cdot (-7) = 1 + 1.4 = 2.4,$$

$$x_1 = 2.4$$

$$f(2.4) = 7.336$$

$$x_2 = x_1 - \gamma \times 7.336 = 2.4 - 1.4 \cdot 7.2$$

$$\boxed{x_2 \approx 0.9328} \quad \approx 0.9328$$

3-1

$$\ell_i(w) = - \left[ y^{(i)} \log(\hat{y}^{(i)}) + (1-y^{(i)}) \log(1-\hat{y}^{(i)}) \right]$$

$$\hat{y}^{(i)} = \sigma(w^T x^{(i)}) = \frac{1}{1 + \exp(-w^T x^{(i)})}$$

$$\ell_i(w) = - \left[ y \log \sigma(s) + (1-y) \log(1-\sigma(s)) \right] \quad (s = w^T x, y = y^{(i)}, x = x^{(i)})$$

$$= \underbrace{\log(1+e^s)}_{f(s)} - ys.$$

$$\ell_i(w) = \log(1+e^{w^T x}) - y w^T x$$

~~$\ell_i(w) = \log(1+e^{w^T x}) - y w^T x$~~ 

$$\nabla \ell_i(w) = \sigma(w^T x)x - yx = (\sigma(w^T x) - y)x$$

Hessian:  $\nabla^2 \ell_i(w) = \sigma(w^T x)(1-\sigma(w^T x))xx^T$

$$\sigma(w^T x)(1-\sigma(w^T x)) \geq 0 \text{이고 } xx^T \text{는 PSD 행렬}$$

$\therefore \nabla^2 \ell_i(w)$  역시 PSD 행렬  $\Rightarrow \ell_i(w)$ 는 convex

$$J(w) = \sum_{i=1}^m \ell_i(w) \text{ 역시 convex}$$

3-3

1) Lagrangian 설정

$$x+y \geq 2 \Rightarrow g(x,y) = x+y-2 = 0. \quad L(x,y,\lambda) = f(x,y) - \lambda(g(x,y)) = x^2 + y^2 - \lambda(x+y-2)$$

$$\begin{cases} L_x = 2x - \lambda = 0 \\ L_y = 2y - \lambda = 0 \\ L_\lambda = -(x+y-2) = 0 \end{cases}$$

$$\begin{aligned} 2x &= \lambda, 2y = \lambda & x &= y \\ x+y &= 2. \quad \Rightarrow x=1, y=1, \lambda=2 \end{aligned}$$

$$f(1,1) = 1^2 + 1^2 = 2$$